

國立中央大學

資訊管理學系

碩士論文

宣告式多因子量化回測系統之設計與實作

Design and Implementation of a Declarative
Multi-Factor Quantitative Backtesting System

研究生：余嫻穎

指導教授：許智誠 博士

中華民國一一五年三月

摘要

量化選股研究在過去數十年間累積了超過四百個具報酬預測力的候選因子（Harvey & Liu, 2019）。然而當研究情境從單一策略驗證擴張至大規模多因子實證，在比較單一時間點截面數值的靜態截面型與追蹤跨期方向性變化的動態跨期型的因子時存在計算邏輯的差異、篩選門檻於有效區間內也有多重組合，使傳統以指令式方式逐案撰寫策略腳本的回測模式於開發效率、腳本一致性與偏誤防控等多項層面均出現結構性的瓶頸。因此本研究在既有回測平台的基礎上，以宣告式設計為核心回應上述問題，設計並實作一套通用量化回測引擎。

本論文的系統架構導入關注點分離原則：將體質、動態變化與估值三類異質計算邏輯以物件導向方式分別封裝，對外則維持統一呼叫介面，允許研究者僅需透過結構化 JSON 設定檔宣告因子構面與條件區間，底層引擎即自動解析並批次生成策略組合。基於此設計，於劉浩平（2024）與李權恒（2024）所開發的回測平台基礎上新建三個模組，分別承擔宣告至計算的轉譯（`condition_factory.py`）、批次展開與執行（`batch_backtest.py`）與獨立的績效分析（`report_analysis.py`）。在財務實證框架上，本研究建構 F-C-V 多層次選股模型，以體質構面（F，例如 ROE、負債比率）篩選財務穩健且具獲利能力之標的，於此基底上引入動態變化構面（C，例如近四季 EPS 年增率連續為正）捕捉成長訊號，最後以估值門檻（V，例如本益比區間）控制進出場風險，並以台灣股票市場 2000 至 2024 年的歷史資料批次回測驗證。

本論文的研究貢獻在於系統以格式固定的外部化設定介面作為輸入、以結構化格式匯出回測結果，使回測引擎在介面形式上符合可被外部程式化呼叫的基本條件，為後續整合 AI 語言模型工具鏈提供架構基礎；各批次實驗的完整設定均以獨立 JSON 檔案保存，支援版本控制與歷史追溯，使大規模因子組合的系統性比較具備可審計的實證基礎。

關鍵字：宣告式設計、量化回測、多因子選股、F-C-V 架構、關注點分離、物件導向封裝

Abstract

The quantitative finance literature has documented over 400 candidate factors claimed to predict stock returns (Harvey & Liu, 2019). When empirical research scales from validating individual strategies to large-scale factor comparison, the divergence between static cross-sectional and dynamic time-series factor logic, the multiple thresholds each factor admits, and the need to align signals across reporting frequencies together strain the traditional imperative approach—where each strategy is coded as a separate script—on development efficiency, cross-script consistency, and bias control.

This study extends an existing backtesting platform with a general engine centered on Declarative Design. The system applies Separation of Concerns and Object-Oriented Encapsulation to isolate the distinct computation logic of quality, change, and valuation factors behind a unified calling interface. Researchers define factor dimensions and condition ranges through structured JSON configuration files; the engine then automatically parses these and batch-generates the corresponding strategy combinations. Three new modules are added: `condition_factory.py` translates declarations into computations, `batch_backtest.py` controls batch expansion and execution, and `report_analysis.py` provides independent performance analysis.

The empirical framework instantiates a multi-layer F-C-V stock selection model: a dual-layer quality filter establishes a robust asset pool (F[1]: financial stability; F[2]: profitability quality); a Change dimension (C) captures momentum signals on this quality-conditioned universe; and a Valuation threshold (V) controls entry and exit risk. Each experiment's full configuration is preserved as a standalone JSON file, providing an auditable, reproducible foundation for large-scale factor comparison. The system's externalized interface and structured output further satisfy the structural prerequisites for programmatic integration into AI language model workflows.

Keywords: Declarative Design, Quantitative Backtesting, Multi-Factor Stock Selection, F-C-V Framework, Separation of Concerns, Object-Oriented Encapsulation

目錄

摘要	
Abstract.....	
圖目錄.....	
表目錄.....	
一、緒論.....	1
1.1 研究背景.....	1
1.1.1 因子選股.....	1
1.1.2 因子之間的交互作用	2
1.1.3 回測系統的偏誤來源.....	3
1.2 研究動機.....	4
1.3 研究目的.....	5
二、文獻探討.....	7
2.1 因子選擇構面	7
2.1.1 三類因子的經濟意涵與定義	7
2.1.2 計算邏輯的異質性與工程問題	8
2.2 物件導向設計	10
2.3 宣告式設計.....	11
2.4 自動化回測系統的架構演進與偏誤防控	13
三、研究方法.....	16
3.1 研究定義.....	16
3.1.1 研究性質與研究目標.....	16
3.1.2 系統設計邏輯.....	16
3.1.3 系統工程驗收標準	17
3.2 策略組合設計邏輯	18
3.2.1 雙層體質濾網建立穩健資產池.....	19
3.2.2 動態變化構面捕捉成長潛力.....	21

3.2.3 估值門檻控制進出場風險	22
3.2.4 三構面組合的具體範例.....	22
3.3 宣告式系統的設計核心.....	26
3.3.1 結構化宣告介面的設計	26
3.3.2 從宣告到執行的轉譯機制	28
3.3.3 策略組合的自動展開	30
3.3.4 設計的整體效果與範圍邊界.....	33
3.4 系統架構.....	35
3.4.1 本研究與原始平台的差異與貢獻.....	35
3.4.2 三層系統架構總覽.....	38
3.4.3 底層繼承：資料存取層與邏輯運算層	40
3.4.4 本研究新建的三個模組	40
3.5 運算效能優化與可重現性.....	41
3.6 實驗驗證框架	42
3.6.1 因子挑選邏輯.....	43
3.6.2 因子區間切分原則	44
3.6.3 實驗對照組設計	45
3.6.4 分析手法	45
四、實驗結果與分析.....	48
4.1 樣本區間與資料來源.....	48
4.2 因子切分規則	48
4.3 實驗結果與分析	51
4.3.1 策略展開與整體績效摘要	52
4.3.2 體質構面分析.....	60
4.3.3 動態變化構面之跨體質穩健性分析	63
4.3.4 估值條件納入影響.....	67
4.4 系統運算效能評估	73
4.4.1 批次運算規模與耗時概況	73
4.4.2 運算效能優化機制的角色	74
4.4.3 工程驗收標準的滿足情況	77
五、研究結論與限制.....	79
5.1 研究結論.....	79

5.1.1 宣告式回測引擎之設計與實作.....	79
5.1.2 F-C-V 多層次選股框架之建構.....	79
5.1.3 工程效能與財務績效之雙維驗證.....	80
5.1.4 介面改造之工程實作與適用前提.....	80
5.2 研究限制.....	81
5.2.1 樣本範圍與市場限制.....	81
5.2.2 因子集規模與構面範圍.....	81
5.2.3 估值構面之條件空間未展開.....	81
5.2.4 策略空間規模化展開之多重檢定風險.....	82
5.2.5 AI 整合屬介面前提而非實作驗證.....	82
5.2.6 實證結果之適用範圍.....	82
5.3 後續研究方向.....	83
六、參考文獻.....	85
附錄 1：實驗規格檔 fcv_experiment_spec.json.....	88

圖目錄

圖 3- 1 F-C-V 三構面遞進關係示意圖.....	19
圖 3- 2 F-C-V 架構展開樹狀示意圖.....	23
圖 3- 3 $F[1] \times F[2] \times C \times V$ 三構面運作流程圖.....	25
圖 3- 4 宣告到遮罩的轉譯與展開流程圖.....	33
圖 3- 5 擴充後之系統架構圖.....	37
圖 4- 1 分析範圍示意圖：章節分析對象為全部 2,084 組策略.....	52
圖 4- 2 Top 10 策略績效熱力圖.....	53
圖 4- 3 單一策略資產曲線與年度報酬分解.....	54
圖 4- 4 單一策略年度股票貢獻度分布.....	55
圖 4- 5 CAGR 前 25% 策略之 Top1 貢獻个股出現頻率（前 20 名）.....	56
圖 4- 6 CAGR 前 25% 策略之 Top1 貢獻个股之報酬貢獻占比（前 20 名）.....	56
圖 4- 7 CAGR 前 50% 策略之 Top1 貢獻个股出現頻率（前 20 名）.....	57
圖 4- 8 CAGR 前 50% 策略之 Top1 貢獻个股之報酬貢獻占比（前 20 名）.....	57
圖 4- 9 累積獲利貢獻曲線：前 25% 與前 50% 策略集合之比較.....	58

圖 4- 10 Effective N 盒鬚圖：前 25% 與前 50% 策略集合之比較	59
圖 4- 11 分析範圍示意圖：本節分析對象為體質構面的單層與雙層篩選效果	60
圖 4- 12 單層體質因子 CAGR 分布盒鬚圖 ($F[2] = \text{None}$ ，涵蓋所有 C/V)	60
圖 4- 13 $F[1] \times F[2]$ 雙層體質因子平均 CAGR 熱力圖 ($C = \text{None}$ ， $V = V0$)	62
圖 4- 14 分析範圍示意圖：動態構面	63
圖 4- 15 不限 F 條件下各動態因子之 CAGR 分布盒鬚圖	64
圖 4- 16 單層體質因子組合於各動態因子下之平均年化報酬率	64
圖 4- 17 $F[1] \times F[2]$ 雙層體質因子組合於各動態因子下之平均年化報酬率熱力圖 ..	65
圖 4- 18 固定不同子樹條件之動態因子 CAGR 分布	66
圖 4- 19 分析範圍示意圖：估值構面	67
圖 4- 20 $V0$ 與 $V1$ 本益比條件下之 ΔCAGR 分布	68
圖 4- 21 ΔCAGR 與 ΔMDD 聯合分布散布圖	68
圖 4- 22 $V0$ 與 $V1$ 於不同體質因子下之 CAGR 分布	69
圖 4- 23 $V0$ 與 $V1$ 於不同動態因子下之 CAGR 分布	70
圖 4- 24 指定子樹條件下之 $V0$ 與 $V1$ CAGR 分布對照	71

表目錄

表 3- 1 $F[1]$ 與 $F[2]$ 分工對照表	20
表 3- 2 條件類型註冊表（在後續實驗中將會使用到的條件類型）	30
表 3- 3 原始平台與本研究貢獻邊界對照表	37
表 4- 1 F 構面因子區間定義	49
表 4- 2 C 構面因子區間定義	50
表 4- 3 實驗執行環境規格	73
表 4- 4 批次回測各階段耗時統計	74
表 4- 5 啟用與停用快取設定下五階段耗時對照	75
表 4- 6 啟用快取設定下五階段記憶體佔用	76

一、緒論

1.1 研究背景

股票市場的因子選股研究長期以財務指標與市場資料為依據，預測哪些股票能取得高於市場平均水準的超額報酬，然而這個研究領域在過去數十年間累積了驚人的因子數量：Harvey 與 Liu（2019）普查頂尖學術期刊，記錄超過 400 個曾被宣稱具有股票報酬預測力的因子；Bartram 等人（2021）則從機構投資人的實務角度梳理全球股票市場研究，指出在任一時點解釋不同股票之間報酬差異的橫斷面因子已逾 450 個。面對如此規模的候選因子，其困難並不僅止於數量眾多，而是計算邏輯的異質性、門檻參數因可選區間眾多而呈幾何級數膨脹的組合規模，以及財報、股價等不同頻率資料之間的時間軸對齊等三個維度的複雜度相互疊加，構成當前量化選股實證研究的方法論瓶頸。

針對上述困境，本研究聚焦於台灣股票市場量化選股場景，以工程系統設計為切入點，探討如何在維持回測嚴謹度的前提下，有效處理大規模多因子策略的自動化實證問題。以下依序從因子計算的異質性、多因子組合的邊際貢獻混淆，以及回測系統的偏誤來源三個面向，剖析此困境的成因。

1.1.1 因子選股

因子數量的爆炸性成長，部分源於學術界在同一批歷史資料上反覆探勘。研究者檢驗的假設愈多，僅憑統計顯著性通過檢定的機率便隨之上升，即使對應的經濟意涵並不成立亦然。Harvey 與 Liu（2019）指出，在已有數百個因子被提出的背景下，傳統 5% 的顯著水準門檻已嚴重低估偽陽性的風險，新因子若要具備可信的預測效力，其統計門檻必須大幅提高。這意味著研究者面對 400 至 450 個候選因子中，相當比例可能是前述反覆探勘下偶然通過顯著性檢定的偽陽性訊號，而非真實的報酬來源，因此對大量因子在統一基準下進行系統性橫向比較，是辨別真實效力與統計雜訊的方法論前提，而非可選的研究選項。

而要系統性比較這些因子，其困難可從以下三個維度說明：

- （一）因子在計算邏輯上存在本質差異：部分因子只須比較特定時間點的財務截面數值，如負債比率是否低於某一門檻、股東權益報酬率是否高於某一水準；另一部分因子則必須在時間軸上追蹤跨期變化，如每股盈餘的年增幅是否連續為正、營收是否創下歷史新高，兩類計算邏輯無法以同一套程式統一處理。
- （二）每個因子的篩選門檻並非固定值，而是一段需要系統性探索的參數區間：以股東權益報酬率為例，研究者須比較門檻設於 5%、10%、15%、20% 等不同水準下的選股結果，才能評估因子的真實效力，然而測試的門檻組合愈多，僅憑隨機波動而通過顯著性檢定的機率也愈高；此即統計學中所稱的多重檢定問題，若研究者未對統計門檻同步調整，所得結論可能僅為統計上的偶然（Harvey, 2017）。
- （三）多類因子交叉組合時不同構面的計算頻率不一致：財務報表以季為單位更新，價格相關指標則以日或月為單位變動，若未對各因子的時間軸嚴格對齊，訊號之間的交叉比較便失去基準（López de Prado, 2018）。

當這三個維度同時作用，研究者所需實證的有效策略組合數量呈幾何級數擴張。現有研究的普遍做法是針對每一個策略組合個別撰寫腳本，在因子數量有限時尚可應付，但面對數百個候選因子與多層次的門檻參數組合，手動維護如此規模的腳本集合在工程上已非偏好的方式，更無法確保每一組腳本在資料前處理與執行條件上完全一致（Arnott et al., 2019）。

1.1.2 因子之間的交互作用

在多因子選股的實務中，因子的有效性往往不能脫離其他因子的背景單獨評估。當財務體質指標與盈餘動態條件同時作為篩選濾網時，若兩類指標背後實際指向同一類風險來源或同一批企業特徵，亦即所對應的經濟曝險相近，導致組合後的超額報酬難以歸因於任何單一構面的獨立貢獻。Bartram 等人（2021）強調，有效因子必須對 Fama-French 五因子模型等已被學界廣泛採用的既有因子模型具備增量解釋力。

這個問題在組合數量有限時尚可藉由文獻梳理與人工判斷控制，然而當需要比較的組合從個位數擴張至數十乃至數百組時問題的性質便發生根本轉變，將不再只是選因子的學術判斷問題，而是如何確保大量組合在相同條件下執行的工程設計問題。若不同組合各自依賴獨立撰寫的腳本執行，資料前處理的細節差異如樣本邊界的界定、極端值的處理方式或換手頻率的設定，便會在組合之間引入不受控的干擾（López de Prado, 2018）。在這種情況下，實驗結果之間的差異無法確定來自因子本身還是腳本設計的不一致，使各因子的邊際貢獻分析從根本上失去可信度。要真正釐清因子的獨立效果，前提是所有組合必須在完全相同的執行條件下運算，而這是一個必須由系統層面統一解決的工程一致性問題（Pardo, 2008）。

1.1.3 回測系統的偏誤來源

當策略實證的規模從單一腳本擴張至大量因子組合的批次執行，回測環境中任何細微的不一致都將被放大為系統性誤差。在量化策略回測中，倖存者偏誤（survivorship bias）、前瞻性偏誤（look-ahead bias）與樣本區間選擇偏誤等被廣泛認為削弱實證可信度的主要偏誤來源（López de Prado, 2018），而多重檢定問題（multiple testing problem）則隨著大規模因子探勘的盛行而成為近年量化研究須優先處理的議題（Harvey, 2017）。

其中，前瞻性偏誤在涉及財務報表資料的選股系統中風險尤為集中。財務報表的法定公告時點與會計截止日之間存在落差，若回測系統未嚴格以公告日作為資料可用的起始點，截面型因子與跨期型因子的訊號均可能誤用尚未公開的資訊，導致績效虛高（López de Prado, 2018）。當不同腳本各自處理此對齊邏輯，各組合之間標準不一致的問題便轉化為系統性雜訊，使橫向比較喪失可信度。在大規模批次實證的情境下，偏誤防控無法依賴研究者對每一份腳本逐一審查，以逐案撰寫的腳本架構為例，財報對齊邏輯散落於各個獨立程式，缺乏統一的控管節點，研究者無從驗證所有組合是否套用了相同的時間邊界定義。因此必須在系統架構層面統一定義資料邊界與時間軸控管規則，方能確保所有組合在相同的嚴格標準下執行（Arnott et al., 2019）。

1.2 研究動機

前述三個維度困境在現有工具環境下仍缺乏整合性的處理方式，就商業回測工具而言，現行平台已能支援以單一時間點財務指標衡量企業狀態的體質因子篩選，研究者可透過介面設定如負債比率或股東權益報酬率等靜態財務指標的門檻並執行單一策略的歷史回測（Sarasa-Cabezuelo, 2023）。然而這類工具對於需要追蹤財務指標跨期變化方向的動態變化因子時支援相當有限。以台灣市場中功能相對完整的選股平台 XQ 全球贏家為例，研究者可透過其介面設定本益比區間、股東權益報酬率門檻等靜態截面條件，但若要篩選「近四季每股盈餘年增率連續兩期為正」此類需要追蹤跨期方向性變化的動態條件，現有介面便無法直接支援，研究者仍需回到程式碼層面自行實作。這說明現行商業工具在靜態因子篩選上已有相當積累，但對動態變化因子的系統性支援仍有明顯缺口，且缺乏將靜態體質濾網與動態變化條件系統性交叉展開、批次比較的整合能力。

就學術研究端的實作方式而言，現有研究的主流做法是為每一個策略組合個別撰寫腳本，各腳本在資料前處理、財報時間對齊與執行條件上各自為政（Arnott et al., 2019）。當需要比較的因子組合擴張至數十至數百組，腳本集合的維護成本與版本一致性便成為研究可信度的實質威脅：不同腳本之間細微的實作差異，足以在橫向比較中引入難以歸因的干擾，使研究者難以確認績效差異源自因子本身的效力，還是腳本設計的不一致（López de Prado, 2018）。

現有量化回測系統在架構設計上存在另一層值得關注的限制：策略邏輯與底層執行高度耦合，輸入條件以硬編碼的形式直接寫死於程式碼中，每次調整都需修改原始碼；回測結果亦多以人工閱讀導向、機器難以直接解析的非結構化格式輸出，使系統難以擴充，也難以從外部呼叫（López de Prado, 2018; Sarasa-Cabezuelo, 2023）。此類封閉性設計在過去主要帶來維護上的不便，而現今隨著 AI 語言模型（LLM）逐漸進入研究輔助工具的應用場景，此限制的影響範圍也隨之擴大。AI 語言模型在實際應用中已逐漸發展出透過外部工具完成計算任務的運作架構，此類運作方式稱為 agent 模式：模型本身不直接執行運算，而是依靠呼叫具備標準介面

的外部工具，以輸入參數驅動計算並讀取結構化的回傳結果（Yao 等人, 2023）。此類介面前提近年已由 Anthropic（2024）提出之 Model Context Protocol（MCP）形式化為一套產業共通的協定。因此若是系統的輸入條件分散於各腳本的硬編碼邏輯中，輸出結果亦以非結構化格式儲存，AI agent 便無從以統一方式呼叫回測引擎，量化研究的計算核心因此難以納入 AI 驅動的自動化研究流程。

上述兩個層次的問題，根源在於現有系統以指令式方式直接將因子定義、門檻設定與底層執行邏輯混寫於程式碼之中。本研究試圖引入的宣告式設計提供了一條不同的路徑，讓研究者透過結構化設定檔定義因子構面與條件區間（Kowalski, 1979），底層不同類型因子的計算邏輯則以物件導向方式各自封裝（Parnas, 1972），系統據此自動解析並批次生成對應的策略組合。每一組實驗的設定均以外部檔案完整記錄，大幅提升策略驗證流程的可重現性（Arnott et al., 2019），同時讓底層邏輯的替換與擴充不影響上層設定介面的一致性。基於此，本研究的動機不僅在於改善因子組合規模帶來的效率困境，更在於以量化回測為實作場景，探索如何將一套既有的量化回測系統透過宣告式設計重構為具備標準化輸入輸出介面的可呼叫工具。回測結果以結構化格式輸出，可直接供 AI 語言模型讀取與分析。此架構轉型所涉及的工程判斷，包括釐清既有系統的介面瓶頸、設計抽象層以分離邏輯與控制、在不重寫核心的前提下為龐大系統建立外部呼叫能力，是一種在 AI 工具鏈快速發展的背景下具有可遷移性的系統改造思路，本研究亦將就此記錄初步的實作經驗，建立討論基礎。

1.3 研究目的

基於前述研究動機，本研究設定四項具體目的，涵蓋系統工程設計、選股框架建構、實驗驗證與系統介面改造四個面向：

- （一）本研究以既有回測平台為基礎，設計並實作一套以宣告式設計為核心的通用量化回測引擎。透過引入物件導向封裝與結構化設定檔機制，將因子定義、條件區間與底層計算邏輯三者分離，使研究者無需修改程式碼即可透過更換

設定檔快速切換因子組合，並由系統統一控管資料時間軸與資料處理邏輯，確保所有批次實驗在相同的嚴格標準下執行。

- (二) 建構整合體質、動態變化與估值三類因子的多層次選股框架，並透過系統自動批次展開的方式，在統一流程下批次回測各種因子組合所生成的選股策略。
- (三) 以台灣股票市場 2000 至 2024 年的歷史資料為樣本，從工程效能與財務績效兩個維度量化驗證宣告式回測系統。工程效能面評估系統在批次策略生成與大規模運算上的實際表現；財務績效面則透過多組策略的回測結果，比較多層條件架構相對於單一構面的績效差異，以實驗結果評估各構面因子的邊際貢獻，為後續因子研究提供可審計的實證基礎。
- (四) 就既有封閉式量化回測系統的介面改造方式提供具體的工程實作與討論，以結構固定、機器可解析的外部化設定介面作為策略定義的輸入方式，同時也以結構化格式匯出回測結果，使系統的輸入與輸出均符合可程式化呼叫的基本條件，達到適合外部工具整合的介面形式。本研究將就此改造過程中的介面設計決策、抽象層的建立方式與適用條件系統性討論，可作為後續延伸應用的參考。

二、文獻探討

本章以系統性文獻回顧的方式，為本研究的工程設計決策建立學術依據。論述依循從問題到解法的順序推進：先確立多類因子在計算邏輯上的本質差異，再說明物件導向封裝與宣告式設計如何逐層透過封裝提供統一呼叫介面，讓宣告式設計在此基礎上實現策略定義與執行的完全分離，最後討論自動化回測系統的偏誤防控標準與 AI 工具適配性的架構基礎。

2.1 因子選擇構面

量化選股研究的核心任務之一是從大量財務指標與市場資料中選出對未來報酬具有預測力的因子，並設計能系統性篩選標的的選股條件。然而，學界數十年累積下提出的候選因子彼此重疊、難以辨識真實效力的現象，亦即文獻所稱的因子動物園現象（Harvey & Liu, 2019; Bartram et al., 2021），所揭示的問題不只是候選因子數量龐大，還包括這些因子在經濟意涵與計算邏輯上的高度異質性。本研究依循財務研究的實證脈絡，將選股因子區分為三類：以靜態財務指標衡量企業體質的體質因子（Fundamentals，F）、以跨期動態變化捕捉基本面成長訊號的動態變化因子（Change，C），以及以市場估值門檻控制進出場風險的估值因子（Valuation，V）。以下先梳理三類因子各自的學術依據，再說明其計算邏輯的本質差異與所引發的工程問題。

2.1.1 三類因子的經濟意涵與定義

體質因子的核心功能在於以財務報表資料篩選具備穩健營運體質的企業，排除財務結構脆弱的標的，建立穩健的候選股票池。Asness 等人（2019）提出品質因子（quality factor）的系統性定義，指出高獲利能力、高成長性與低財務槓桿的企業，在長期回測中能產生穩定且顯著的超額報酬，確立了將財務體質納入量化選股的理論必要性。Fama 與 French（2015）的五因子模型亦證實獲利能力與投資規模是解釋預期報酬的核心變數，使以淨利率、股東權益報酬率（ROE）等指標衡量企業盈利品質的做法獲得廣泛的學術支撐。在防禦性指標的選擇上，Piotroski（2000）以九項財務訊號建構綜合評分體系，實證確認負債比率等財務穩健指標能有效過濾

潛在的財務風險標的；Ball 等人（2016）則指出，剔除應計項目（accruals）干擾後以現金為基礎的營業獲利，較傳統盈利指標更能精確反映企業的真正獲利能力。

動態變化因子（為敘述簡潔，後文簡稱動態因子）的設計出發點與體質因子不同；體質因子衡量的是企業在某一時間點的靜態財務狀態，動態變化因子則追蹤財務指標跨時期的變化方向與幅度，目的在於捕捉正處於基本面持續改善階段的企業。Chan 等人（1996）在盈餘動能（earnings momentum）的研究中指出，市場對企業盈餘驚喜（earnings surprise）的反應具有持續性，盈餘向上修正的企業在後續數季中往往持續產生超額報酬，是以財務指標動態變化作為選股依據的早期實證基礎；Jegadeesh 與 Livnat（2006）同樣確認，季度營收超預期是具有持續效力的正向訊號。這類動態變化訊號的共同特徵，在於其判斷依據是一段期間內的方向性變化，而非某一時間點的截面水準。

估值因子的功能定位不同於前兩類，其作用是在完成體質與動態篩選後排除估值過高的標的以控制進場風險。Basu（1977）最早以實證研究確認本益比（P/E）的反向預測能力，低本益比的企業在長期回測中系統性優於高本益比企業，為估值因子的選股效力提供了早期的學術依據。Campbell 與 Shiller（1998）從長期視角確認市場估值比率對後續報酬具有預測力，高估值環境下的進場決策在統計上面臨更高的下行風險；Asness 等人（2013）在跨市場與跨資產類別的大樣本實證中，確認估值訊號在與動能訊號結合時能提升選股的風險調整後報酬。估值因子的計算邏輯，與體質因子相近，均以特定時間點的財務比率或市場價格進行截面比較，屬於靜態的布林篩選條件。

2.1.2 計算邏輯的異質性與工程問題

上述三類因子雖然在財務研究上各有理論依據，但從系統工程角度觀察，體質因子與估值因子在計算上同屬一類，動態變化因子則自成一類；且每類因子的有效閾值並非單一定值，而是一段需要系統性探索的參數區間。三項特性相互疊加，構成系統工程設計上必須處理的複雜度。

體質因子與估值因子的計算，均是對財務報表或市場資料在特定時間點的截面數值設定閾值，其計算邏輯本質上是單一時間點的數值比較，不涉及跨期的序列運算。惟即使同屬靜態截面型，不同指標之資料更新頻率仍有差異：獲利能力與財務結構類指標多以年報或季報為週期更新，估值類指標則隨日資料變動；於同一觀察日上，各指標對應之有效資料時點不盡相同。此一頻率異質性使靜態截面型因子之計算仍須由系統統一處理時間軸對齊，以維持條件比較之一致性。

動態變化因子的計算則截然不同（López de Prado, 2018），所需判斷的不是某個時間點的數值而是某個指標在一段期間內的變化方向。以「近四季每股盈餘年增率連續兩期為正」為例，系統必須取得當期與前五季的每股盈餘資料，計算每一期相對於去年同期的增減幅度，再判斷這個增減幅度在最近兩個觀察點是否均為正值。這個判斷涉及在一段移動的時間窗口內取出特定期數的資料、計算跨期之間的差分，以及對多個時間點的序列條件評估，所產生的布林遮罩會隨每一期的資料更新而動態演進，無法以靜態截面型的計算架構取代。

在計算邏輯的差異之外，因子的有效閾值本身也無法以單一數值代表，這也使策略空間的規模放大。財務研究的方法論要求研究者須對每一個因子的篩選門檻做系統性的區間測試，而非任意選定一個固定值。以 ROE 為例，研究者若只測試「 $ROE \geq 15\%$ 」這一個條件，無法確認該門檻設定是否最具區分力；唯有同時比較 $ROE \geq 5\%$ 、 5% 至 10% 、 10% 至 15% 、 15% 至 20% 等不同區間的選股結果，才能評估不同水準的財務體質門檻對報酬的影響是否具有單調性，以及在何種範圍內因子的預測效力最為穩健。Harvey（2017）指出，量化研究若在同一批資料上反覆挑選最佳參數組合而未進行多重檢定修正，所得結論極可能是統計上的偶然而非真實的因子效力。這個方法論要求對每一個因子均成立，無論是靜態截面型的體質指標、動態跨期型的動態條件，還是估值門檻，都各自對應一段需要探索的有效參數區間。

當三類因子各自在多個閾值水準上展開，並進行跨構面的交叉組合，所產生的策略數量便從各因子數量的線性加總，擴張為所有閾值區間與因子類型的乘積，形成幾何級數規模的策略空間。在策略數量有限時，傳統指令式方式尚可藉由分開撰

寫腳本加以應付，而當系統同時需要處理涵蓋兩類計算邏輯、跨越多個閾值區間的大量因子組合時，若將靜態截面計算與動態跨期計算混寫於同一套程式碼，程式的耦合程度會隨因子數量的增加急速上升。每新增或修改一個動態因子的時間窗口定義，就必須深入程式碼調整跨期計算邏輯，且這種調整難以在不影響其他因子的前提下單獨進行。Parnas（1972）在討論系統模組分解的準則時即指出，將具有不同變化特性的計算邏輯混寫於同一模組，會使任何局部修改的影響範圍難以預期，大幅提升維護成本。在多因子回測的脈絡下，這意味著不同批次實驗之間因子邊界定義的一致性與時間軸對齊的標準均無從透過個別腳本的審查保證，從而形成難以追溯的系統性偏誤風險。這說明有效的多因子回測系統，在架構設計上必須具備一套能同時容納異質計算邏輯、又能對外維持統一呼叫介面的封裝機制，方能在大規模批次實驗中同時兼顧計算正確性與結果可比性。

2.2 物件導向設計

前述章節的分析指出，體質因子與動態變化因子在底層計算邏輯上本質不同，若以指令式方式混寫，系統的耦合程度會隨因子數量上升而急速惡化。要解決這個問題，需要一種能將不同的計算邏輯各自隔離、同時又能讓上層程式以統一方式驅動所有因子運算的設計機制，而物件導向設計（object-oriented design）正是解決此類問題的核心工程方法。

物件導向設計的基礎在於將模組內部容易變動的計算細節封裝起來、僅對外暴露穩定呼叫介面的設計原則，此即封裝（encapsulation）與資訊隱藏（information hiding）兩項核心概念的共同精神。Parnas（1972）在討論系統模組分解的準則時提出，模組的邊界應以「隱藏設計決策」為原則：凡是可能隨需求改變的計算細節，應封裝在模組內部，對外只暴露穩定的呼叫介面。依照此原則，異質計算邏輯得以各自封裝於獨立類別內部，外部呼叫者無須知曉實作細節，僅透過統一介面驅動運算並取得布林遮罩；此一封裝機制為 2.1.2 節所描述的因子計算耦合問題提供處理路徑。

封裝機制的另一層意涵在於多型性（polymorphism）所帶來的可互換性。Gamma 等人（1994）在設計模式（design patterns）的系統性整理中指出，當不同的物件類別對外實作相同的介面時，呼叫端可以在不修改自身程式碼的情況下替換底層的具體實作，即所謂的「對介面設計，而非對實作設計」原則。在多因子系統的脈絡下，三類因子雖各自封裝截然不同的計算邏輯，僅須對外實作相同的計算介面，上層的主控制流程便得以同一套迭代邏輯依序呼叫所有因子，無須為每一類因子撰寫專屬驅動程式碼。新增因子類型時僅須實作對應的類別與介面，無須修改上層邏輯，系統因此具備可擴充性。

這個設計在多因子回測系統中的具體效果，是讓底層計算邏輯的多樣性與上層控制流程的一致性得以同時成立。底層各類別分別負責其計算邏輯的正確實作，彼此之間互不干涉；上層主程式只與統一介面互動，不需知道正在呼叫的是體質因子還是動態變化因子。Sarasa-Cabezuelo（2023）亦指出，將策略定義與底層執行流程分離並以結構化介面統一管理資料處理邏輯，是降低人為操作不一致所引入之偏誤風險的關鍵工程原則。物件導向所建立的統一呼叫介面，正是在架構層面實現這種分離的具體機制，使偏誤防控的一致性由介面設計本身保障，而非仰賴研究者對個別腳本逐一審查。

物件導向封裝所建立的統一介面也為下一層的設計抽象提供了必要的基礎，當所有因子均能透過相同的介面呼叫，上層的主控制流程不再需要了解因子的計算細節。正是在這個前提成立之後，宣告式設計才得以在物件導向所提供的架構基礎上運作；於此一架構基礎之上讓策略定義與底層執行得以於介面層面徹底分離，使大量因子組合無須各自撰寫程式邏輯。使得引擎可以自動解析宣告，透過統一介面驅動底層所有因子的批次運算，讓每一組因子組皆無需獨立撰寫程式邏輯，同時將策略定義與底層執行因此在架構層面徹底分離。

2.3 宣告式設計

物件導向封裝所建立的共同呼叫介面是宣告式設計得以在多因子回測系統中發揮作用的工程前提。在底層異質計算邏輯已被統一封裝的基礎上，上層主控制流程

不再需要了解個別因子的計算細節，只需依序呼叫各因子的共同介面並傳入對應參數。正是在這個條件成立之後，研究者才得以從撰寫策略腳本的工作中抽身，轉而以更高層次的方式描述要測試哪些因子、套用哪些條件區間，而由系統負責自動完成底層的所有運算。

宣告式設計的理論基礎，源於 Kowalski (1979) 提出的經典命題：演算法等於邏輯加控制 (Algorithm = Logic + Control)。Kowalski 的核心主張是，一個完整的運算任務可以被分解為兩個獨立的層次：邏輯層描述需要滿足什麼條件、達成什麼目標，控制層則負責以何種方式、何種順序執行這些目標。兩個層次的分離使得研究者只需專注於邏輯層的宣告，控制層的執行細節則交由底層引擎統一處理。此分離對應到的架構安排是應邏輯層由因子構面與條件區間之宣告構成，控制層則為驅動所有因子之執行機制，物件導向所建立的共同介面，使控制層無論底層計算邏輯如何複雜或異質皆以一致方式對待所有因子。

宣告式系統在實作層面需要一種外部設定格式，使研究者能以結構固定、機器可解析、且不依賴程式語言語法的方式描述因子宣告。這種格式必須同時滿足兩個條件：其一，格式本身須足夠輕量，使研究者在不具備底層程式背景的情況下仍能編寫與修改設定內容；其二，格式須具備固定的結構規範，使引擎能以統一的解析邏輯讀取任意研究者提交的設定而不因個別撰寫習慣的差異導致解析失敗。Sarasa-Cabezuelo (2023) 在討論現代回測系統架構時指出，透過參數化介面設計讓策略開發者得以跳脫繁瑣的底層程式實作是現代回測系統架構的核心發展方向；結構化的輕量資料交換格式正是實現此設計原則的具體載體，使因子宣告與底層執行流程的耦合得以在介面層面徹底消除。López de Prado (2018) 亦強調，將運算目標與資料控制流程分離不僅能提升策略開發的可重現性，更能由底層引擎統一控管資料時間軸，從根本上降低前瞻性偏誤與資料探勘偏誤的風險。

這個設計的實質效果是讓策略定義與執行運算成為兩個完全獨立的動作：更換測試因子或調整條件區間僅須於宣告層次修改，底層執行邏輯無須觸碰。且每一組實驗的設定亦得以外部檔案完整保存，由統一之引擎邏輯驅動，使大規模因子組合

的系統性比較於工程上具備可行性。可以由宣告式設計解決的是策略定義與執行分離的問題；當系統能夠自動批次生成並執行數百組策略組合時，確保每一組策略在相同的資料邊界定義下運算，便成為決定實驗結果是否具備橫向可比性的關鍵品質標準，讓這個問題的性質已從個別腳本的人工審查，轉變為回測系統在架構層面必須主動解決的偏誤防控工程課題。

2.4 自動化回測系統的架構演進與偏誤防控

宣告式設計使系統得以在統一的執行邏輯下批次處理大量策略組合，但這也意味著底層資料處理邏輯的任何不一致將同時影響所有批次實驗的結而非只波及單一腳本，因子回測偏誤的工程防控因此成為自動化回測系統設計中不可迴避的品質標準。

從自動化回測系統的發展脈絡來看，這個認識的形成本身就是一段從效率優先轉向嚴謹性優先的演進過程。早期的量化研究多依賴研究者為特定策略撰寫完整的指令式程式碼，涵蓋資料讀取、條件運算、訊號生成與績效計算的全部邏輯。這種開發方式在驗證單一策略時尚可應付，但在面對大規模因子實證時，暴露出兩個根本性的限制：

- （一）每新增或替換一個因子，研究者便需深入程式碼修改，開發效率隨策略數量的增加急速下降。
- （二）各策略腳本在資料前處理邏輯上各自為政，使不同策略的回測結果難以在統一基準下橫向比較。

上述兩項限制共同指向同一個方法論問題：策略邏輯與底層資料處理的耦合，使大規模實證比較難以在統一基準下進行。Arnott 等人（2019）指出，具備可重現性的回測框架必須透過標準化的資料處理流程統一管理資料取得、前處理與績效評估，以降低人為介入所引發的不一致風險，確立了將策略邏輯與底層資料處理分離作為自動化回測系統設計核心目標的發展方向。

在自動化回測框架的發展脈絡下偏誤防控從研究者的個別責任成為系統架構必須統一承擔的設計任務。第一章已說明前瞻性偏誤、倖存者偏誤等問題的成因，從工程角度而言，這些問題的根源在於資料邊界的定義分散於各個獨立腳本，缺乏統一的控管節點。Pardo（2008）指出，穩定且具可比性的實驗結果必須建立於一致的評估基準之上，這唯有透過層次化架構將資料處理邏輯集中管理方能達成。López de Prado（2018）則指出，量化研究中最難察覺的偏誤來源正是研究者在反覆修改腳本的過程中無意間引入的資料外洩，而集中管理資料存取邊界的架構設計是從根本上消除此類風險的工程方法。這兩項研究共同指出，隨著批次規模的擴大，偏誤防控的工程責任必須由分散式腳本向集中式架構轉移，才能確保大規模批次實驗的橫向可比性。

時間對齊問題的困難之處在於其影響隨批次規模的擴大而成倍放大。當研究者只執行少數策略組合時，尚可逐一審查每份腳本的財報日期設定；當批次實驗擴展至數十乃至數百組因子組合，若對齊邏輯分散於各個獨立腳本，不同腳本之間即使存在細微的日期設定差異，累積下來也足以在組合間的績效比較中引入系統性雜訊。這說明在大規模批次實證的情境下，偏誤防控已從研究者的逐一審查問題，轉變為系統架構的設計問題，必須由底層引擎統一定義資料邊界與時間軸控管規則，方能確保所有組合在相同的嚴格標準下執行。

上述文獻的發展脈絡說明，一套具備研究價值的自動化回測系統其品質標準不只是策略能否被批次執行，更在於所有批次實驗是否在相同的資料邊界定義下運算使結果的橫向比較具備方法論上的可信度，而這個認識與宣告式設計所建立的架構集中管理原則高度契合：當資料邊界的定義由底層引擎統一執行，而非分散於各個獨立腳本，偏誤防控的一致性便由架構本身保障。

在此工程基礎之上，系統的外部化設定介面設計也在另一層面具有延伸意義。Yao 等人（2023）在提出 ReAct 框架時指出，語言模型以代理模式運作時，依賴格式固定的行動輸出與可解析的環境回傳結果，兩者共同構成模型與外部工具互動的結構性前提；缺乏此類標準介面的封閉系統，無從被語言模型納入推理與行動的交

替循環之中。Anthropic（2024）則提出 Model Context Protocol（MCP），將此一介面前提形式化為連接語言模型與外部工具的標準協定，並於 2025 年起被各主要語言模型平台採納為事實標準。宣告式系統所建立之外部化設定介面與結構化輸出，於介面形式上即符合此類標準協定對伺服端工程前提之要求。

三、研究方法

3.1 研究定義

3.1.1 研究性質與研究目標

本研究為一量化研究，研究對象是一套以宣告式設計為核心的通用回測引擎，研究目標是建置本引擎並以實證結果驗證其架構的有效性。本章會以下列各節先說明系統設計邏輯與組成（3.2 至 3.5 節），再以 3.6 節建立整體實驗驗證框架作為第四章實證分析的依據。

第一章所設定的四項研究目的，依序為建置以宣告式設計為核心的通用量化回測引擎、建構整合體質、動態變化與估值三類因子的多層次選股框架、從工程效能與財務績效兩個維度量化驗證此一架構，以及就既有封閉式回測系統之介面改造提供具體工程實作。對應此四項目的，本研究於系統建置層面須達成下列工作：

- （一）計算層：建立物件導向封裝下的共同計算介面，使體質、動態變化與估值三類因子的異質計算邏輯能對外以統一形式呼叫，讓後續因子類型擴充時無須改動上層控制流程。
- （二）控制層：以結構化設定檔作為策略宣告的外部介面，並建立批次展開與標準化儲存機制，使研究者得以在不修改核心程式碼的前提下變更測試因子與門檻，且大量策略組合能在相同的資料邊界與交易規則下執行並橫向比較。
- （三）介面層：使系統的輸入與輸出均符合可程式化呼叫的基本條件，達到適合外部工具整合的介面形式，可作為後續延伸應用的參考。

3.1.2 系統設計邏輯

建構量化選股系統時若依賴逐案撰寫單一策略腳本，在處理大量因子組合時將面臨開發效率低落，且難以在完全相同的基準下進行橫向比較。為克服瓶頸，本研究的系統設計邏輯建立於兩項核心原則之上。

- (一) 邏輯解析抽象化：將因子的宣告內容與其底層計算流程分離，並以結構化格式保存。
- (二) 多層次可替換構面：如第 2.1 節所述，多因子組合時若不同因子反映相近的經濟曝險，組合後的邊際貢獻將難以歸因於單一構面，因此系統應要可以將性質互異的特徵解耦為可替換的多維度構面，透過系統化展開產生結構清晰且具橫向可比性的策略組合。以一個實務情境說明：研究者若同時以高 ROE 與 EPS 連續成長兩個條件選股、發現績效不錯，將難以回答這份績效究竟來自獲利能力的篩選，還是來自盈餘動態的篩選，若兩者其實對應的是同一批公司，研究者會誤以為自己掌握了兩個有效因子，實際上只有一個。構面解耦的價值，正是讓研究者能分別關掉某一層、單獨觀察另一層的效果，從而判斷真正應保留的是什麼。

上述兩項核心原則同時涵蓋本研究所處理的兩類計算邏輯，亦即採單一時間點截面比較的體質因子（F）與估值因子（V），以及採跨期序列運算的動態變化因子（C）。

3.1.3 系統工程驗收標準

系統工程層面的驗收標準包含三項核心要求：

- (一) 可重現性：每一組實驗的設定均以外部檔案完整保存，相同設定檔於相同引擎版本下執行應產出相同的回測結果，且所有批次實驗均由同一套引擎邏輯驅動，不因執行時點或研究者不同而產生結果差異。
- (二) 彈性擴充能力：新增或替換既有類型內的因子時（例如於體質構面中將 ROE 替換為 ROA）僅需修改設定檔內容，而不需更動核心回測程式碼。而當系統要引入新的因子類型時（例如於既有的靜態截面型與動態跨期型之外新增波動度類因子），僅需實作對應的計算類別並接入共同介面，上層批次主程式的控制邏輯無須調整，使因子集的擴充不致成為後續研究的阻力。
- (三) 回測偏誤的系統性修正：底層引擎統一控管資料時間軸，以實質生效日對齊規避前瞻性偏誤，並涵蓋歷史下市標的以消除倖存者偏誤。此項要求的關鍵

在於將偏誤防控的責任由個別腳本上移至系統架構，使所有批次實驗均在相同的嚴格標準下執行。

3.1.4 架構有效性驗證模型

除工程層面的驗收外，本研究另建立架構有效性驗證模型，以檢驗 F-C-V 三構面框架在實證上是否成立。驗證分為兩層：第一層為工程層驗證，著眼於引擎作為工具的工程可行性；第二層為框架層驗證，著眼於 F-C-V 三構面框架在實證上的有效性。

本研究將以三項常見的策略績效指標作為判斷準則依據：年化報酬率（Compound Annual Growth Rate, CAGR）衡量策略於回測期間的長期複利增值能力；最大回檔（Maximum Drawdown, MDD）衡量策略於歷史樣本中遭遇的最大跌幅，反映下檔風險；夏普值（Sharpe ratio）衡量單位風險下的超額報酬，於回測中以策略日報酬序列計算其樣本平均與樣本標準差（標準差以 $n - 1$ 為分母），於無風險利率取 0 之假設下，將兩者比值乘以年化乘數 $\sqrt{252}$ （對應一年之交易日數）後作為年化夏普值；後續所報之夏普值皆為此一年化值。

判斷準則的建立原則不追求單一數值上的統計顯著性，而是以樣本分布的整體形態與跨組差異作為架構有效性的實證支持。具體而言，判斷準則涵蓋三類。其一，不同構面加入後，CAGR 與 MDD 在對照組之間的差值（以下簡記為 ΔCAGR 、 ΔMDD ）呈現的分布位移方向。其二，於固定體質子樣本（即 $F[1] \times F[2]$ 展開樹狀結構中的特定分支，以下簡稱子樹）下，各動態因子的 CAGR 中位數順序。其三，估值門檻於不同 F 與 C 條件組合上達成預期風險控制的策略比例。三類判斷準則的具體操作化方式，依實驗對照組設計（3.6.3 節）與分析手法（3.6.4 節）兩節共同定義。

3.2 策略組合設計邏輯

本研究採用 F-C-V 三構面架構作為策略組合設計的根基，其設計邏輯呼應一個直觀的投資判斷順序：先確認該公司值得持有，再確認它正在往好的方向走，最後

確認現在是合理的進場時機。體質構面（F）回答的是這是否是一家財務健全、獲利穩定的好公司，如負債比率、股東權益報酬（ROE）等衡量企業的安全邊際與盈利品質的財務指標。動態變化構面（C）對應的是公司的基本面近期是否持續在改善，通常以盈餘年增率、營收創新高等跨期變化訊號辨識正在加速成長的標的。估值構面（V）要確保的是現在的市場價格是否仍在合理範圍內進場，大多以本益比等估值指標控制買在過高價位的風險。

三個問題依序篩選，每一層都在前一層的基礎上進一步縮小候選範圍，使最終選出的標的同時具備體質、動態與價格三個維度的支撐。三個構面各自對應第 2.1.1 節所述的三類因子文獻脈絡，彼此不重覆曝險，組合後的邊際貢獻得以獨立辨識。以下先說明採用此三構面架構的理由，並依序展開體質構面分為雙層的設計、動態變化構面的必要性、估值構面的控制功能，最後以一組具體的實例示範三構面如何在系統內組合運作。

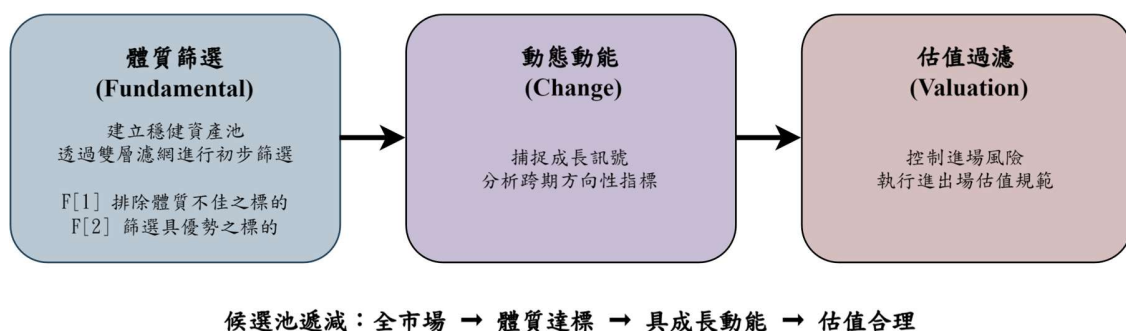


圖 3-1 F-C-V 三構面遞進關係示意圖

3.2.1 雙層體質濾網建立穩健資產池

體質構面的設計目的是在所有後續分析展開之前排除財務結構明顯脆弱的標的，為整個選股流程建立穩健的候選資產池，本研究將體質構面拆為兩層，分別承擔不同的篩選職責。

將體質構面拆為雙層的理由在於單一體質門檻難以同時兼顧風險防禦與獲利品質的評估。如 2.1.1 節所述，財務研究對「體質」的操作化包含兩種不同性質的指標：一類指向財務結構的安全邊際（Piotroski, 2000），另一類指向企業的獲利能

力與盈利品質（Fama & French, 2015; Ball et al., 2016）。若將兩類指標不分層次地套用於同一道篩選，一方面研究者無法辨識最終通過篩選的標的是因財務風險低而入選，還是因獲利能力強而入選；另一方面，兩類指標的門檻嚴格程度若彼此牽動，研究者亦難以在控制一類指標的前提下獨立調整另一類，而雙層設計在這兩個問題上同時提供解決。

本研究之雙層體質濾網分工如下：

- F[1] 基礎體質濾網：目的為建立安全邊際，檢驗標的當期財務結構與流動性指標，剔除極端高槓桿或流動性明顯不足的企業。常見 F[1] 指標包含負債比率、流動比率、利息保障倍數等，以負債比率為例，實務上一般以 50% 為財務結構分水嶺，長期高於此水準的企業在景氣下行或利率上升時，利息負擔與再融資壓力會明顯放大，下檔風險也隨之升高。該層的功能在於排除潛在財務風險標的，而非挑選獲利突出者。
- F[2] 進階體質濾網：目的為挑選具穩定獲利能力之標的，於通過 F[1] 的標的之上，以核心獲利能力指標如 ROE、每股盈餘（EPS）或毛利率為基礎，調整門檻高低以形成不同嚴格程度的獲利品質子樣本。以 ROE 為例，長期維持 15% 以上的企業通常具備穩定的競爭優勢或訂價能力，這類公司在歷史回測中往往能累積較穩健的報酬；不同水準的 ROE 門檻則用以辨識獲利能力嚴格到何種程度時，篩選對報酬的區辨效果才開始顯現。

兩層分工的關鍵在於邏輯互不重疊：F[1] 排除壞標的，F[2] 挑選好標的，這樣的分工使研究者得以在同一時間點平行比較不同嚴格程度的獲利條件（F[2] 層的多重配置）在相同安全基底（F[1] 層）上的效果，為後續的穩健性分析提供結構基礎。

表 3-1 F[1] 與 F[2] 分工對照表

比較面向	F[1] 基礎體質濾網	F[2] 進階體質濾網

篩選目的	排除財務結構脆弱之標的	挑選具穩定獲利能力之標的
常用指標	負債比率、流動比率、 利息保障倍數	ROE、EPS、毛利率
文獻脈絡	Piotroski (2000) 等防禦性財務訊號	Fama 與 French (2015)、 Ball 等人 (2016) 等獲利能力因子

3.2.2 動態變化構面捕捉成長潛力

確立標的具備穩健體質後，本研究引入動態變化構面（C）尋找處於基本面持續改善階段的企業。相較於體質構面著眼於單一時間點的財務狀態，動態變化構面追蹤財務指標在一段期間內的變化方向與幅度，目的是捕捉體質已獲確認、近期仍持續改善的標的。

動態變化構面的文獻依據源自盈餘動能與基本面動態的實證研究（Chan et al., 1996; Jegadeesh & Livnat, 2006），此類研究指出，市場對企業盈餘改善的反應往往不是一次到位而是隨後續財報陸續確認逐步反映於股價；連續幾季持續優於去年同期的企業，其改善趨勢通常會延續一段時間，股價也隨之逐步反映。這類訊號的共同特徵，在於其判斷依據是一段期間內財務指標的方向性變化，而非某一時間點的截面水準。動態變化構面在本研究架構中的角色，是體質篩選之後的「成長訊號過濾器」，本設計考量有二：

- （一）體質基底的必要性：若不先建立穩健體質基底，動態變化訊號可能捕捉到的是體質不佳企業的短期反彈，而非可持續的基本面改善。

(二) 計算邏輯的區隔：動態變化訊號與體質訊號屬於不同時間尺度的觀察，前者需要跨期序列資料，後者依賴單一時間點的截面資料，兩者的計算邏輯本質不同。

本研究將動態變化構面獨立設計為可替換的一層，而非與體質指標混編，正是為了讓兩類訊號的邊際貢獻得以獨立辨識。

3.2.3 估值門檻控制進出場風險

基本面體質優良且具成長動態的企業往往也正是市場最追捧、股價最貴的時候，若是選在這個時間點進場可能導致預期報酬空間遭壓縮，且一旦市場情緒反轉或實際成長略不如預期，回檔的幅度將特別劇烈。因此估值構面的功能即是在體質與動態兩層篩選之後，對通過前兩層的標的施加進出場的估值規則排除估值明顯偏高者，寧可錯過部分漲勢，也避免在估值最極端的時點進場。

估值構面在本研究中設計為獨立的進出場層，而非融入體質篩選，其考量在於兩類指標的經濟意涵不同。體質指標衡量企業本身的營運品質，估值指標則衡量市場價格相對於企業基本面的合理性；兩者若混用於同一層篩選，將使挑選好企業與以合理價格買進的判斷混為一談。本研究的分層處理可使估值構面的邊際效果得以獨立檢驗。後續第四章中將以具體實證命題展開：於相同的體質與動態條件下，加入估值門檻能否有效改善最大回檔，並在何種程度上影響報酬水準。

3.2.4 三構面組合的具體範例

3.2.1 至 3.2.3 節已分別說明體質、動態變化與估值三個構面的設計分工，當這三個構面依本研究的 $F[1] \times F[2] \times C \times V$ 架構交叉展開時，由單一組條件所決定的策略會延伸為一個具有層次關係的策略集合。為讓讀者先掌握展開的整體規模，圖 3-2 呈現本研究以 F-C-V 架構為根、逐層開枝的策略展開樹狀結構。

此樹狀結構由頂至底共有六層節點，最頂端的 FCV 代表三構面架構本身的概念根節點，其下 F1 至 F4 為 F[1] 層的候選因子。每一個 F[1] 因子節點再分支至 F[2] 層的候選因子（包括 F1、F2、F3、F4 作為進階體質），同欄位自配的組合於展開

時排除。F[1] × F[2] 組合決定之後，每一個組合節點再向下分支至 C 層，對應 C1 至 C7 等動態變化條件；最末端的葉節點則對應 V 層的兩種配置，v0 為不套用估值門檻、v1 為套用本益比進出場規則。任何一條從根節點至葉節點的完整路徑，即對應系統中一組具體的策略設定；所有葉節點的集合，則構成本研究完整的策略空間。




圖 3-2 F-C-V 架構展開樹狀示意圖

樹狀結構所呈現的是系統層面的策略規模感，其中每一條從根至葉的完整路徑都對應一組具體的策略設定。為讓讀者從抽象的構面分工轉為具體的架構運作，本節以其中一條路徑所對應的條件組合作為示範。此範例僅用於解釋架構邏輯，第四章實際採用的完整因子集與區間切分詳見 4.2 節與 4.4.1 節。

示範條件如下：

- F[1] 基礎體質：負債比率 $\leq 50\%$ 。確保這是一家不會因財務槓桿過高、在景氣下行或利率上升時容易因利息與再融資壓力而受創的公司。
- F[2] 進階體質：ROE $\geq 10\%$ 且 EPS > 0 。確保這家公司確實具備獲利能力、能為股東創造報酬，而非僅止於不虧損。
- C 動態變化：近四季 EPS 年增率連續兩期為正。確保這家公司的盈餘不只穩定，而是正處於持續向上的趨勢。
- V 估值門檻：本益比 ≤ 20 倍。確保即使前三層都通過，也不會在市場已給出過高定價的時點追高進場。

本示範條件對應樹狀結構中的一條具體路徑。在此路徑上，系統於每一個歷史時間點依序執行下列四層判斷：

- F[1] 層：自全市場標的中取得當期負債比率不超過 50% 者，作為體質基底。
- F[2] 層：於此基底中保留 ROE 至少 10% 且 EPS 為正者，形成獲利品質達標之子樣本。
- C 層：於此子樣本中篩選出近四季 EPS 年增率最近兩期均為正者，辨識具有盈餘動態之標的。
- V 層：於動態達標之標的中，保留當期本益比不超過 20 倍者作為實際進場標的。




圖 3-3 F[1] × F[2] × C × V 三構面運作流程圖

上述段落示範呈現的是樹狀結構中單一條從根至葉的路徑所對應的執行動線。實際研究中，本研究須比較不同 F[1] 指標、不同 F[2] 門檻組合、不同 C 條件類型與不同 V 區間設定的多重搭配以辨識各構面與各區間的邊際貢獻，完整的策略空間即為圖 3-2 所有葉節點的集合。此 F[1] × F[2] × C × V 的層次結構已足以適用大部分的因子分析，若後續研究需要新增更多體質濾網層次、或於 F-C-V 之外引入其他構面，僅需依循本研究中提出的現有邏輯，於批次主程式中展開並新增對應的展開層即可，降低後續研究者延伸本架構的擴充門檻。

3.3 宣告式系統的設計核心

3.2 節所確立的架構在概念上完備，但當架構真正擴展為大規模的實證比較時，策略組合的數量、資料邊界的一致性、以及設定內容的追溯能力，三者共同構成系統設計必須同時解決的工程挑戰。本研究以 1.2 節與 2.3 節所論述的宣告式設計回應先前提過的多種挑戰，將依序展開此設計的三個層次，包括結構化宣告介面、從宣告到執行的轉譯機制，以及策略組合的自動展開。

本節所展開之宣告式設計於工程實作上承續 2.2 節之物件導向原則，將靜態截面型與動態跨期型兩類異質計算邏輯分別封裝於獨立的工廠函式之中，對外以一致的呼叫形式運作（接收資料表、回傳布林遮罩），使上層批次主程式得以同一套迴圈驅動所有條件之計算；新增條件類型時亦僅需於註冊表中加入對應工廠，上層控制流程不受波及，此封裝的形式是宣告式設計得以在上層維持統一驅動邏輯之必要條件，其具體實作機制詳見 3.3.2 節。

3.3.1 結構化宣告介面的設計

宣告式介面必須同時滿足三項要求：其一，須具備固定的結構規範，使系統得以統一解析任意研究者提交的設定內容，不因撰寫習慣差異而導致解析失敗；其二，須足夠輕量，讓研究者在不具備深厚程式背景的情況下仍能修改與擴充；其三，須與底層實作語言解耦，使相同的宣告內容可被不同的引擎實作讀取。依此三項要求權衡後，本研究選用 JSON 作為宣告介面的具體載體，JSON 作為通用的結構化資料交換格式語法簡潔而規範清晰，同時具備跨語言的普遍支援，符合上述三項要求。

在 JSON 設定檔的層級結構上，本研究採用構面分區、因子、條件清單三層嵌套設計，最外層為構面分區，以 P1 對應 F 構面所使用的靜態截面型因子、P3 對應 C 構面所使用的動態跨期型因子，將兩類計算邏輯在設定檔階層上即予以分離。P2 所對應的 F[2] 進階體質濾網在本研究設計中並非獨立的因子來源，而是由 P1 條件清單派生而來的第二道篩。設定檔本身不需要獨立的 P2 區段。第二層為因子，每一個因子作為一個鍵值，其內部包含兩個必要欄位，分別為對應底層資料欄位的 field，以及該因子之下所有待測條件的 conditions 清單。第三層為條件規格，每一

個條件以固定語法 {type, args} 描述，type 標示條件類型、args 提供該類型所需的參數。以本研究實際使用的 fcv_experiment_spec.json 為例，P1 區段中 ROE 因子的宣告節錄如下：

```
"ROE": {
  "field": "report:roe",
  "conditions": [
    {"type": "lt_strict", "args": [5]},
    {"type": "between", "args": [5, 10]},
    {"type": "between", "args": [10, 15]},
    {"type": "between", "args": [15, 20]},
    {"type": "gte", "args": [20]}
  ]
}
```

程式碼 3-1 P1 區段中 ROE 因子的宣告節錄

此宣告將 ROE 因子劃分為五個不重疊的區間，每個區間對應一個待測條件。逐區間宣告而非設定單一門檻的意圖，在於研究者並無法事先得知 ROE 須達何種水準才具區辨力，亦無法確定報酬與 ROE 之間是否單調遞增；將區間分層宣告於設定檔中，等同於讓資料本身回答因子的有效範圍。P3 區段中動態變化因子的宣告結構相同，但 type 所描述的是跨期序列判斷，並額外加入 prefix 欄位作為最終策略命名的辨識前綴。以 ROE_SEQ 為例：

```
"ROE_SEQ": {
  "field": "report:roe",
  "conditions": [
    {"prefix": "C1_", "type": "is_highest_q", "args": [4]},
    {"prefix": "C2_", "type": "rise_q", "args": [1]},
    {"prefix": "C3_", "type": "yoy_gt", "args": [4]}
  ]
}
```

程式碼 3-2 P3 區段中 ROE_SEQ 因子的宣告節錄

此結構設計的效果是研究者只需宣告因子名稱、條件類型與參數，不需關心系統內部如何取得資料、如何對齊時間軸、如何執行計算。此分離的副產物是設定檔

本身即具備自我說明性，每一組實驗的完整參數化配置均以一個獨立的 JSON 檔案保存，支援版本控制與歷史追溯，這對於大規模批次實驗的可審計性具有實質意義，亦使日後對任一批次實驗的回溯重建有完整可循的依據。¹

3.3.2 從宣告到執行的轉譯機制

上述宣告介面的固定結構是為系統的自動轉譯的必要前提，然而宣告本身只是形式上的描述，真正承擔宣告式設計核心責任的是轉譯機制，亦即如何將 JSON 中的文字宣告轉化為底層引擎可實際執行的計算。如 2.1.2 節所述，靜態截面型與動態跨期型因子的計算邏輯本質不同，轉譯機制的設計必須同時處理這兩類邏輯且不讓兩者的差異外洩至上層控制流程。若這兩類計算邏輯混寫於同一套程式碼，程式的耦合程度會隨因子類型的增加急速上升。具體而言，若不封裝，每一個新增的動態跨期因子都需要在上層控制邏輯中加入對應的 if 分支以判斷該因子屬於哪一類計算邏輯；當因子類型從個位數擴充至十餘種，上層控制邏輯的分支複雜度將使程式的可維護性快速惡化。本研究的處理方式是建立一個統一的條件註冊表，搭配一套以工廠函式為核心、由其依宣告參數動態生成已綁定參數之條件函式的閉包工廠模式，使兩類計算邏輯在內部實作上得以各自隔離，但對外維持完全一致的使用方式，研究者無須區分自己正在呼叫的是哪一類因子。

註冊表的具體形式為一個將條件類型字串映射至工廠函式的字典，命名為 `CONDITION_FACTORY`。每一個條件類型對應一個工廠函式；當 JSON 中出現某個 type，系統透過此字典即可定位到對應的工廠。工廠函式本身是閉包的具體應用，其職責是接受 JSON 中宣告的參數，並回傳一個預先綁定參數的條件函式。本研究於工廠模式的具體實作上選擇閉包而非類別（class）封裝，原因在於條件函式本身不需要維持內部狀態，閉包的實作較類別更為簡潔，且 Python 中透過閉包綁定參數是此類工廠模式的通用做法。以最基本的區間判斷為例：

¹完整的 `fcv_experiment_spec.json` 設定檔內容，詳見附錄。

```
def between_factory(lower, upper):
    return lambda s: (s >= lower) & (s < upper)
```

程式碼 3-3 between_factory 的實作

呼叫 `between_factory(10, 15)` 所得到的，是一個已將上下界鎖定為 10 與 15 的函式，此函式接受一個 DataFrame 輸入，回傳對應的布林 DataFrame。動態跨期型條件的工廠同樣遵循此介面約定，只是內部實作複雜得多。以「較上 n 季上升」的 `rise_q_factory` 為例：

```
def rise_q_factory(n: int):
    def _cond(s):
        df = _as_df(s)
        q = _compress_report_updates(df)
        cond_q = q > q.shift(n)
        out = cond_q.reindex(df.index, method="ffill").fillna(False)
        return out
    return _cond
```

程式碼 3-4 rise_q_factory 的實作

此工廠所產生的條件函式，在內部須先將日頻序列壓縮回公告更新點序列、於低頻序列上執行跨期比較、再對齊回日頻索引。但其對外呼叫形式與靜態條件完全一致：接受一個 DataFrame、回傳一個布林 DataFrame，此即「內部異質、對外同質」的封裝效果，是宣告式設計得以在上層維持統一驅動邏輯的工程前提。

在所有動態跨期條件的實作中，將日頻 ffill 序列壓縮回公告更新點的前處理步驟，屬於共通的正確性要求。若略過此步驟而直接在日頻序列上執行 `rolling(window=4)`，得到的是「近四個交易日」而非「近四季」的比較結果。為避免每一個跨期工廠各自實作前處理、並確保一致性，本研究將其抽離為獨立的輔助函式 `_compress_report_updates`，供所有跨期條件工廠共用。此決定在架構層面的意義是將跨期計算的正確性不再依賴個別研究者對財報日頻 ffill 特性的理解，而是透過共用元件統一保障。

基於以上轉譯機制的基礎，研究者若需要新增尚未支援的條件類型，成本極低。新增一個靜態門檻類型，只需實作一個單行函式並於 CONDITION_FACTORY 字典中註冊；新增一個動態跨期類型，則可直接套用既有的 _compress_report_updates 作為前處理，只需專注於核心比較邏輯的實作。整個 build_conditions 函式以及上層的所有控制流程，在擴充過程中完全不需修改。本研究於實驗中實際使用的七種條件類型，包含三種靜態截面判斷與四種跨期序列判斷，其標示、語意與參數意涵彙整於表 3-2。除此之外，CONDITION_FACTORY 亦預先註冊了橫斷面排名類（例如 is_largest 每期取前 n 大標的）與穩定度類（例如 diff_abs_lt 判斷指標前後期變動是否穩定）的工廠函式，作為後續研究擴充的基礎。

表 3-2 條件類型註冊表（在後續實驗中將會使用到的條件類型）

類型標示	類別	計算語意	參數意涵
lt_strict	靜態截面	嚴格小於給定門檻	門檻值
between	靜態截面	落於給定區間（左閉右開）	區間下限、上限
gte	靜態截面	大於等於給定門檻	門檻值
rise_q	跨期季度	較前 n 季上升	季數
is_highest_q	跨期季度	近 n 季最高	窗口季數
yoy_gt	跨期季度	較上年同季上升	對齊期數 （預設 4）
ytd_avg_gt_prev_year _same_period_avg	跨期季度	本年至今平均 大於去年同期平均	無

3.3.3 策略組合的自動展開

轉譯機制將宣告語法轉化為條件函式清單之後，下一步是將這些條件依本研究的三構面架構自動組合為完整的策略集合。研究者在 JSON 中只宣告了各構面的條

件清單，並未逐一列舉策略組合；策略組合由系統依固定的展開規則自動生成，自動展開的邏輯分為三層，對應 $F[1] \times F[2]$ 、 $F \times C$ 、加入 V 的順序。

第一層展開處理體質構面的雙層組合，實作上 $F[1]$ 與 $F[2]$ 並非兩個獨立的 JSON 區段而是由同一份 $P1$ 條件清單派生。研究者於 $P1$ 區段宣告各體質條件後，系統依設定將每一個 $P1$ 條件指派為 $F[1]$ 的候選，再從同一份 $P1$ 清單中挑出所有欄位不同的其他條件作為 $F[2]$ 的候選，並於候選清單中保留一個空集合作為僅套用 $F[1]$ 的基準線，使單層濾網的策略得以與套用雙層濾網的策略在同一批次下直接比較。排除相同欄位自配的規則是為了避免例如 ROE 區間 10 至 15 疊加 ROE 區間 5 至 10 這類在語意上無意義且必然產生空集合的組合。最終，每一個 $F[1] \times F[2]$ 組合的布林遮罩，即兩道條件布林遮罩的邏輯交集。此設計的額外意義在於架構的彈性，系統不預設哪些因子必須放在 $F[1]$ 、哪些必須放在 $F[2]$ ，研究者可透過設定檔中的因子清單與 3.2.1 所建立的分工原則自行決定，不需要為了雙層設計而撰寫兩個分離的 JSON 區段。

第二層展開在每一個 $F[1] \times F[2]$ 組合之上疊加動態變化條件，研究者於 $P3$ 區段宣告各動態條件後，系統取出所有條件函式，對每一個 F 組合依序套用所有 C 條件，並同樣保留一個未套用任何 C 條件的候選項。每一個最終組合的布林遮罩，為 F 組合之遮罩與 C 條件之遮罩的邏輯交集。透過這一層展開，系統在單一批次內同時生成了 F -only 與 $F+C$ 兩種配置的策略，為後續檢驗動態構面的邊際貢獻提供了對照基礎。

第三層展開加入估值門檻，估值構面同樣納入宣告式管理，惟其宣告形式較 F 、 C 構面精簡：研究者於批次執行時以代號（ $v0$ 或 $v1$ ）選用對應的估值配置，系統依此選擇套用相對應的條件規則，無需於 JSON 中逐一展開條件區間。 $v0$ 表示不套用任何估值限制， $v1$ 為當季本益比低於近四季平均且高於近四季最低的相對估值條件，採用近四季的相對區間而非絕對門檻，使估值判斷以個股自身的歷史本益比序列為參照，避免不同產業之間絕對本益比水準差異造成的橫向比較失真。 $v0$ 與 $v1$ 的具體語意對應 Graham（2003）所提出之安全邊際（margin of safety）原則的

操作化：低於近四季平均對應以自身歷史估值水準為參照、排除當前估值明顯偏高的進場時機，高於近四季最低則避免在估值極端壓縮的階段進場（此類情境通常伴隨該標的基本面出現尚未反映於財報的異常），此設計取「略低於歷史平均但未達極端折讓」的相對估值區間，作為本研究驗證估值保護效果的單一對照條件，而採用近四季的移動窗口而非單一時點則是為了降低單期盈餘波動對估值評估的干擾。

V 構面之所以於本研究中固定採兩個對照配置（v0、v1）而未進一步展開估值條件空間，理由有二。其一，本研究的實證重點在於檢驗體質構面的雙層分工與動態構面的邊際貢獻，估值構面的角色是進出場規則而非選股因子，探討的是在體質與動態篩選之後加入估值門檻能否改善風險與報酬特性這一單一問題，不需要大規模的估值條件空間展開。其二，將 V 構面維持為可控制的固定對照（v0 對 v1），能讓後續分析在同一 $F \times C$ 條件下精確比較 v0 與 v1 的績效差異。因此策略展開的最終結果，是每一個 $F \times C$ 組合都衍生出 v0 與 v1 兩個版本，形成完整的策略空間。

展開完成後，系統將每一組策略以結構化的形式記錄為策略名稱對應布林遮罩的對照表，策略名稱依固定規則組成：以雙底線分隔的字串，依序對應 F[1]、F[2]、C、V 四個層次。以 ROE_10_15_EPS_>=2_C1_ROE_SEQ_qmax4_v0 為例，該名稱包含三個區段。第一段 ROE_10_15 與 EPS_>=2 由因子 ROE 與 EPS 之區間定義自動組合而成。第二段 C1_ROE_SEQ_qmax4 由 C 構面之衍生條件名稱、底層欄位 ROE_SEQ、條件類型 is_largest_q 與參數 4 自動組合而成。第三段 v0 表示未套用估值限制，從名稱本身即可反推該策略的完整配置，這在後續大規模策略分析中具有實質的可審計價值，遇有疑問之策略亦能透過名稱直接追溯其設定來源，不需翻找原始 JSON。




圖 3-4 宣告到遮罩的轉譯與展開流程圖

3.3.4 設計的整體效果與範圍邊界

綜合前述三個層次，研究者若需替換測試因子只需修改 JSON 中的因子名稱或 field 對應；若需調整門檻區間，只需修改 conditions 清單中的 args。3.3.2 所述的條件類型擴充機制，亦確保了當研究需要新增尚未支援的條件類型時，上層批次主程式與展開邏輯均無須變動。此外，系統支援多個 JSON 設定檔於同一次執行中批次載入，各設定檔彼此獨立處理、互不合併，每份設定檔產出各自完整的策略集合與回測結果。此設計使研究者得以在同一次實驗中並行比較多套參數配置，例如對同一組核心因子分別測試寬鬆與嚴格兩種區間切分，各自獨立回測後再橫向比較。

此設計同時存在兩層明確的範圍邊界。其一，V 構面雖同屬宣告式管理，於本論文中固定採用 v0、v1 兩個對照配置，未對估值條件本身展開條件空間。此為本研究實證範圍的決策而非系統能力的限制，原因在於 V 的探討在本研究中聚焦於估值門檻納入前後的對照，不需要與 F、C 同等規模的區間展開。若後續研究需要以同樣的方式檢驗多種估值條件，僅需依循 F 與 C 的相同模式於 JSON 中宣告對應條件，即可納入批次展開流程。其二，三構面的組合順序與展開結構由自動展開邏輯寫死於程式碼中，並非 JSON 設定可變動的範圍，而其理由在於四層篩選架構對本研究所設定的實證範圍已屬充分，不需要在展開結構本身進行額外的實驗變異。若後續研究需要調整層數或插入新的構面層級，展開邏輯的修改範圍僅限於批次主程式中的展開函式，不影響條件解析工廠與底層回測引擎。

此外，宣告式設計所建立的外部化介面，也使本系統在介面形式上具備被外部工具程式化呼叫的基本條件。系統的輸入為格式固定的 JSON 設定檔，輸出為結構化的標準化儲存檔，兩者均不依賴系統內部的記憶體狀態或互動式操作。這種輸入輸出形式使回測引擎得以作為獨立的計算服務被外部程式納入自動化流程，在介面層面符合 Yao 等人（2023）所指出之語言模型與外部工具互動所需的結構性前提。

此一介面前提近年已由 Anthropic（2024）提出之 Model Context Protocol（MCP）形式化為一套標準協定，MCP 採 client-server 架構，伺服器端（MCP server）以 JSON-RPC 2.0 訊息對外暴露三類能力，分別為可被語言模型呼叫之函式（tools）、可讀取之結構化資料（resources）與預先定義之提示樣板（prompts）（Anthropic, 2025）。OpenAI 已於 2025 年宣布支援此一協定，目前已成為各大語言模型平台連接外部工具的事實標準。MCP 對伺服器端的工程前提包含三項：呼叫進入點集中、輸入參數結構化、輸出格式可程式化解析；本研究系統的批次主程式作為單一執行入口、JSON 設定檔作為結構化輸入、標準化儲存檔作為結構化輸出，三項條件均已具備。據此，本系統若於後續研究中包裝為 MCP server，僅需於應用層之上加入協定介面層，將批次執行與結果讀取兩項操作分別暴露為 tool 與 resource，核心的回測引擎、條件解析工廠、批次展開邏輯均無需改動。

基於此介面定位，本系統可在 AI 驅動的研究流程中對應兩類使用情境。其一，AI 透過 MCP 呼叫本系統執行回測：研究者以自然語言描述欲驗證的因子組合與門檻區間，AI 依本系統 JSON 設定檔的格式規範生成對應內容、透過 MCP 觸發批次執行並取得回傳結果。其二，AI 對本系統輸出進行後續分析：本系統的標準化儲存檔得以直接作為 AI 的輸入，協助研究者就大規模批次結果做排序、跨組比較與報告撰寫。需要說明的是，本研究在範圍上聚焦於建立上述兩類情境所需的介面前提，實際的 MCP server 包裝、AI agent 串接與分析示範均屬後續延伸方向，不在本研究實作驗證的範圍之內。

3.4 系統架構

3.3 節所展開的宣告式系統需具體對應到一套清楚分層的模組組成才能在工程上實現並長期維護。以下說明本研究的系統架構，包含本研究的貢獻邊界、三層架構總覽、底層繼承內容，以及新建模組的具體功能。

3.4.1 本研究與原始平台的差異與貢獻

本研究並未從頭建立量化回測系統，而是在劉浩平（2024）與李權恒（2024）所開發的回測平台基礎上擴充應用層、補強資料對齊邏輯。原始平台所提供的能力聚焦於回測引擎的底層運作基礎涵蓋三個層次，資料存取層以 `get_data.py` 與 `database.py` 負責連線 MySQL 資料庫並取得股價、財報與大盤資料；邏輯運算層涵蓋 `backtest.py`、`backtest_core.py` 等模組，實作單一策略的交易撮合、部位管理、因子計算與結果彙整；應用層的 `report.py` 則產出回測報告物件，各模組的具體定位與本研究的使用方式詳見表 3-3。

原始平台的回測引擎本身已具備單一策略回測的完整能力，但其設計定位並非為大規模多因子組合的批次實證而建。具體而言，原始平台的選股條件以硬編碼方式直接寫入程式碼，研究者若要測試新的因子組合，必須手動撰寫對應的選股邏輯；以單一策略為執行單位，並未內建將大量策略組合以統一基準展開並批次執行的機制；在跨期動態因子的資料時間軸對齊上，亦未形成系統性的保障機制。

基於原始系統的上述特性，本研究於應用層做兩項主要擴充，於邏輯運算層新增一項模組並補強跨期資料對齊邏輯。應用層的兩項擴充包含：建立 `batch_backtest.py` 作為批次展開與排程執行的控制中樞、建立 `report_analysis.py` 作為標準化儲存檔之獨立績效分析模組。於邏輯運算層，本研究新建 `condition_factory.py` 作為 JSON 宣告與底層計算之間的轉譯工廠；並補強跨期動態因子計算所需的資料對齊邏輯，使跨期運算先於低頻序列上完成、再對齊回日頻索引，避免因日頻 `ffill` 特性而產生的跨期計算錯誤；此項補強整合於批次流程中，不另行新增獨立模組。

本研究擴充後的系統架構如圖 3-5 所示，與原始平台的具體貢獻對照整理於表 3-3，其中「沿用」表示本研究直接使用原始平台所提供的模組或能力、「本研究新建」表示對應模組完全由本研究新建、「本研究補強」表示本研究於原始平台基礎上補強既有能力。




圖 3-5 擴充後之系統架構圖

應用層新增 batch_backtest.py 與 report_analysis.py 兩個本研究自建模組，邏輯運算層新增 condition_factory.py 作為條件解析模組；其餘模組沿用劉浩平（2024）與李權恒（2024）所開發之原始平台。

表 3-3 原始平台與本研究貢獻邊界對照表

層級	模組	原始平台	本研究

資料存取層	get_data.py 、 database.py	連線 MySQL、取得原始資料	
邏輯運算層	dataframe.py	自訂資料結構 CustomDataFrame	沿用
	backtest.py 、 backtest_core.py	單一策略交易撮合 與部位管理	
	combinations.py	多策略回測執行與 結果集合管理	
	report.py	回測報告物件與績 效指標計算	
	跨期資料對齊邏輯	無系統性機制	本研究補強
	condition_factory.py	無	本研究新建
應用層	batch_backtest.py	無	本研究新建
	report_analysis.py	無	本研究新建

3.4.2 三層系統架構總覽

本研究擴充後的系統承襲原始平台的三層分工由下至上依序為資料存取層、邏輯運算層與應用層，各層之間的職責分工明確，層與層之間透過穩定的呼叫介面連接，使任一層的內部實作變動不會波及相鄰層，這是本架構在長期維護上得以延續的基本條件。

資料存取層位於架構最底層，負責與資料來源介接。本研究的系統中使用 MySQL 資料庫作為原始資料來源，儲存台股股價、財報基本面指標與大盤指數等

資料。此層之下有 `database.py` 負責資料庫連線與原始查詢，以及 `get_data.py` 取得對應的資料表，並回傳為上層可直接運用的 `DataFrame` 結構。

邏輯運算層位於架構中層，承擔資料前處理、因子計算、時間軸對齊與策略執行，此層內部可再區分為三個功能模組。

- (一) 資料框架模組以 `dataframe.py` 提供 `CustomDataFrame` 作為統一的資料結構。
- (二) 條件解析模組以本研究新建的 `condition_factory.py` 承擔 JSON 宣告與底層計算之間的轉譯，將外部化的條件宣告轉為可套用於資料框架的布林遮罩。
- (三) 回測模組以 `backtest.py` 與 `backtest_core.py` 實作單一策略的交易撮合、部位管理與績效計算，並以 `combinations.py` 管理多策略結果的彙整。

應用層位於架構最上層，承擔研究者與系統之間的互動入口，此層新增兩個模組：`batch_backtest.py` 作為批次回測的主程式入口、`report_analysis.py` 作為回測結果的獨立分析入口。此外，研究者亦可透過 `dataframe.py` 直接操作資料作為輔助入口，應用層的模組呼叫邏輯運算層的各模組介面，完成從條件解析、批次執行到結果分析的完整流程。

三層架構的責任分工可總結如下：資料存取層負責取得並標準化原始資料、邏輯運算層承擔條件解析與策略執行、應用層則提供批次控制與研究者操作的介面。各層的內部實作均封裝於其層內，上層僅透過穩定介面呼叫下層能力，不直接涉及下層的實作細節。

在實際執行中，資料於三層之間的流動採取由應用層向下呼叫的模式。應用層的 `batch_backtest.py` 呼叫邏輯運算層的 `condition_factory.py` 取得條件函式，再呼叫資料存取層的 `get_data.py` 取得原始資料，由條件函式套用於資料產出布林遮罩，最後呼叫邏輯運算層的函式執行回測。

3.4.3 底層繼承：資料存取層與邏輯運算層

為使系統擴充聚焦於真正需要變動的層次，本研究於資料存取層完全沿用原始平台的實作不另行擴充。邏輯運算層中的資料框架模組、回測模組與報告模組（詳見表 3-3），均沿用原始平台的實作。

邏輯運算層所進行的唯一補強為跨期動態因子的資料對齊邏輯，如 3.3.2 節所述，跨期動態條件在計算上必須先於低頻序列（公告更新點）上完成 rolling 運算，再對齊回日頻索引；此邏輯若未正確處理，跨期運算的結果將不符預期，因此在該模組中對齊邏輯作為跨期動態因子計算正確性的統一保障。

3.4.4 本研究新建的三個模組

為將原始平台從單一策略回測擴展為大規模因子組合的批次實證工具，本研究於系統中新建的三個模組，分別為位於邏輯運算層的 `condition_factory.py`（條件解析模組），以及位於應用層的 `batch_backtest.py`（批次回測主程式）與 `report_analysis.py`（績效分析模組）。三個模組各自承擔不同的職責，彼此之間透過標準化的資料交換介面連接，使批次展開、策略執行與結果分析在架構上明確解耦。

第一個模組為 `condition_factory.py`，作為 JSON 宣告與底層計算之間的轉譯工廠。此模組的核心職責已於 3.3.2 節完整展開，此處僅補充其在系統架構中的定位：條件解析工廠接受 JSON 設定檔作為輸入，回傳一個以條件名稱為鍵、以條件函式為值的清單，作為批次主程式後續展開的依據。此模組不會直接呼叫回測引擎，其輸出僅為條件函式清單；而策略組合的展開與回測執行由批次主程式承擔。此分工使條件解析的邏輯不與批次執行邏輯耦合，兩者得以各自獨立修改與測試。

第二個模組為 `batch_backtest.py`，作為批次展開與排程執行的控制中樞。原始平台的回測函式接受的輸入是一個已展開的條件字典而不承擔展開邏輯；因此 `batch_backtest.py` 的核心貢獻即在於建立展開層，使大規模策略組合得以依架構自動生成，並統一餵入回測函數執行。具體而言，此模組承擔三項任務：其一，讀取條件解析工廠所產出的條件函式清單，依本研究的 $F[1] \times F[2] \times C \times V$ 架構自動展

開所有有效的策略組合；其二，將展開後的條件字典執行批次回測；其三，將回測後產生之持股軌跡、交易明細與績效指標以標準化的檔案格式匯出，供後續分析使用。此處運算與儲存分離的設計是本模組的關鍵取徑：回測運算完成後不直接繪圖或計算進階指標，而是先將結果以標準化格式保存，使後續的分析工作得以在不重跑回測的前提下反覆進行，對於涉及數千組策略的批次實驗而言，這一分離大幅降低了分析階段的時間成本。

第三個模組為 `report_analysis.py`，作為獨立的績效分析入口。此模組讀取批次主程式所匯出的標準化儲存檔，產出熱力圖、邊際貢獻分析、盒鬚圖與獲利集中度檢驗等進階分析圖表。本模組與批次主程式之間僅透過標準化儲存檔連接，不共享記憶體或執行狀態，這一設計使分析工作得以與回測運算在時間上完全解耦，並支援研究者在不同時點、不同分析視角下對同一批回測結果反覆探索。

三個模組共同構成本研究批次回測的完整流程：`condition_factory.py` 負責把 JSON 變成條件函式，`batch_backtest.py` 負責把條件函式展開為策略、執行回測、匯出結果，`report_analysis.py` 負責把結果變成可供分析的圖表。三個模組以標準化介面連接，共同構成本研究對 3.2 節所提之大規模多因子實證工程挑戰的具體回應。

3.5 運算效能優化與可重現性

前述 3.3 與 3.4 節所展開的宣告式系統與三層模組架構，在設計層面已完成系統的整體規劃。然而，當架構實際面對數千組策略的批次回測時，兩項決定批次實驗能否順利進行的條件隨之浮現：其一，運算效能是否足以讓批次回測在合理時間內完成；其二，不同時點執行的同一批次實驗是否能產出完全一致的結果。本節就此兩項議題，說明本研究在實作層面所採取的處理方式。

在運算效能方面，大規模批次回測的主要瓶頸來自布林遮罩的計算與回測績效的結算兩個環節。本研究對此採行兩項效能處理。第一，導入快取機制，將已對齊的資料表與已計算的中間遮罩保存於記憶體中，避免不同策略之間重覆取得相同資料或重覆計算相同的基礎遮罩；同一個 `F[1]` 條件的布林遮罩在所有包含此 `F[1]` 的策略組合中只會計算一次，後續組合直接取用快取結果。第二，布林遮罩的生成與

條件判斷均以向量化方式處理，避免逐檔迴圈帶來的等候時間累積。此外，原始平台的底層回測引擎已於核心數值運算函式中導入編譯加速技術，本研究沿用既有能力，不另行重寫。上述機制共同確保批次回測能在合理時間內完成，使大規模實驗得以納入正常研究週期，而非成為單次成本過高、難以反覆執行的特殊任務。

在可重現性方面，本研究的保障機制建立在三個層次之上。第一個層次為實驗設定的外部化保存。每一批次實驗的完整因子配置均以獨立的 JSON 設定檔保存，使任何時點的研究者均可依據設定檔重現該批次的完整策略空間。第二個層次為回測結果的標準化儲存，`batch_backtest.py` 將每一組策略的持股軌跡、交易明細與績效指標以標準化檔案格式匯出，使後續分析不依賴回測當下的記憶體狀態，而是完全基於已保存的檔案進行。第三個層次為資料時間軸的統一控管，確保系統於任何模擬交易節點上僅使用該時間點市場已公開的歷史資訊。底層資料模組依據台股財報的法定公告時程，將各類財報資料對齊至其實質可用的起始日期：年報（第四季報）對齊至次年 3 月 31 日，第一季報對齊至 5 月 15 日，第二季報對齊至 8 月 31 日，第三季報對齊至 11 月 15 日。系統自動完成財報類型判別與對齊日期指定，並以前推補值方式將同一季的財報數值沿用至下一次財報公告之前，使對齊邏輯由底層統一執行，所有策略組合在相同的時間邊界定義下運算，讓研究者無須逐一審查每份腳本的日期設定，系統即於架構層面保證所有策略均以模擬時點上真實可得的資訊做選股決策，這是大規模批次回測結果具備可信度的根本前提。

上述效能優化與可重現性機制共同構成本研究批次回測的工程可行性基礎，效能機制確保大規模策略組合能在合理時間內完成回測，可重現性機制確保不同時點執行的同一設定能產出一致結果。兩者搭配 3.3 與 3.4 所建立的宣告式設計與三層架構，使本研究的實驗流程得以同時兼顧規模、效率與嚴謹度。

3.6 實驗驗證框架

為驗證系統與其所承載的框架在實證上是否成立，以下說明本研究的實驗驗證框架，涵蓋因子挑選依據、區間切分原則、對照組設計、分析手法，以及兩層驗證之間的關係。

先就本研究採用之分析取徑說明其方法論依據，傳統多因子實證研究常以 Fama-MacBeth 等迴歸框架估計各因子之偏迴歸係數，此類做法所隱含的假設是各因子在解釋報酬上具備可加性、彼此可互相替代，因子之間的差異僅在權重不同。然而選股決策的真實結構並非如此：F、C、V 三構面並非三個並列的解釋變數，而是三道有先後順序的資格篩選：體質不過關的標的，並不適合進入動態變化構面的計算範圍，因為一家體質脆弱企業所呈現的盈餘改善訊號，其經濟意義與一家體質穩健企業的同樣訊號截然不同。若以迴歸將兩者納入同一變數，所估得之係數將無法分辨此二者，因子效力的解讀亦失去明確意義。本研究因此採用階層式條件篩選，依序固定上層條件、觀察下層因子之相對效果，使因子效力得以在上層資格已通過的子樣本內被乾淨辨識。此一方法論選擇是因應選股決策本身之條件式、有序結構所做的取徑調整，亦使後續第四章之分析得以對應 F-C-V 之遞進設計逐層展開。

3.6.1 因子挑選邏輯

如第 2.1.1 節所述，量化選股文獻對體質、動態變化與估值三類因子的經濟意涵已有充分積累。本研究從各類因子中挑選具代表性的指標作為實驗對象，挑選準則有二：其一，該指標在文獻中已有一定程度的實證支持，能對應到明確的經濟面向；其二，該指標在台灣股市的資料可得性足以涵蓋研究所需的完整樣本區間。

在本研究最終確定 F 構面四項因子與 C 構面八項衍生條件之前，系統設計階段曾於宣告式介面上測試過 30 餘項候選因子，橫跨獲利能力（ROE、ROIC、CROIC、RONOA、利潤率）、現金流（OCF/E、OCF/總資產、自由現金流殖利率）、財務結構（負債比率、現金償債能力、淨營業資產比）、R&D 強度（R&D/銷售、R&D 資本化、折舊強度）、應計品質（異常應計、總應計）、估值（P/IC、現金流殖利率、現金流/市值）、動量（12 個月減 1 個月動量、1 個月反轉、動量變化）、波動（報酬率波動）與成長（盈餘驚奇、銷售成長、長期營業資產成長）等多項經濟構面之候選指標。最終以因子定義之經濟意涵明確度、台股資料覆蓋之完整性以及與既有因子之非冗餘性三項準則為依據，篩選出本研究實際呈現之配置。其餘候選因子於同一宣告式引擎下均能正常執行批次回測，本研究選擇集中分析具備代表性且能完整支撐 F-C-V 架構之子集，以便於後續構面比較。

在體質構面（F）採用四項指標：ROE 對應獲利能力、EPS 作為盈餘基礎與動態構面的衍生依據、負債比率（Debt ratio）對應財務結構安全性、自由現金流除以市值（FCF Yield）對應股利支付能力。

在動態變化構面（C）以前述 F 類指標為基礎，設計八種跨期變化條件（詳見 4.4.1），包含歷史新高、年增率、季增率與跨期平均比較等樣態。本設計刻意將 C 類建立在 F 類指標之上，目的是讓動態變化訊號能與體質基底共用同一組原始資料，避免因新增指標而引入額外的資料邊界問題。

在估值構面（V）採用本益比作為代表指標，以第 2.1.1 節所引述的估值因子文獻為基礎，採用簡化的進出場規則作為控制進場估值風險的工具。

本研究並非以窮舉所有可能因子為目標，而是以具備代表性且能支撐 F-C-V 架構完整運作的最小因子集作為驗證對象。此設計選擇的方法論意涵在於：若本研究的宣告式引擎能以少量代表性因子展開為大規模策略組合，並產出可辨識的實證差異，即足以支持架構的有效性主張；反之，若小規模因子集無法產出有意義的結果，則架構本身的擴充潛力亦難以成立。

3.6.2 因子區間切分原則

因子的有效閾值並非單一固定值，而是一段需要系統性探索的參數區間（Harvey, 2017），因此本研究對每一個因子採兩種切分原則並用，以兼顧理論依據與資料特性。

第一種原則為文獻與實務常見基準。部分因子在文獻中已有廣泛引用的門檻水準，例如負債比率 50% 作為財務風險常見分界、本益比作為便宜、合理與偏貴的分段基準。採用此類既有基準的目的，在於讓實驗結果得以與既有研究對話，不使區間切分成為一個脫離文獻脈絡的自由選項。

第二種原則為歷史分布分位數。本研究針對每一個因子於完整樣本期間的歷史資料，計算平均數、中位數及四分位數（25%、50%、75%），將區間邊界對照該

指標在歷史樣本中的位置。此舉的目的有二：避免區間落在極端樣本區段而失去代表性；避免區間劃分完全依賴主觀判斷而引入資料探勘偏誤。

兩種原則並用時，優先採用文獻基準，再以歷史分布驗證該基準是否落在樣本的合理區段。若兩者出現明顯落差，則於第四章記錄該落差並說明最終採用的切分依據。

3.6.3 實驗對照組設計

本研究的實驗驗證核心是檢驗 F-C-V 三構面框架中，各構面加入後是否帶來可辨識的邊際效果。為此設計三組對照：

- (一) F-only：此組作為基準線，僅以體質構面篩選，不疊加動態與估值條件。為實驗驗證提供單一構面績效分布的初步輪廓；作為後續加入 C 與 V 時的邊際比較基礎。F-only 組本身再分為單層（僅 F[1]）與雙層（F[1] 加 F[2]）兩種配置，以檢驗雙層體質濾網設計的必要性。
- (二) F+C：在固定體質條件下交叉不同動態因子，驗證動態構面是否能在體質基底之上帶來邊際績效增益。由於動態訊號的強度可能受體質條件的異質性干擾，本組的分析手法採「固定子樹」的方式，將特定體質條件的策略獨立出來比較，以控制體質異質性對動態效果的稀釋。
- (三) F+C+V：在第二組之上疊加估值門檻，驗證的重點並非估值是否一律提升報酬，而在於辨識估值門檻在什麼樣的 F 與 C 條件組合下能達成預期的風險控制效果。具體判準是 CAGR 與 MDD 的變動量（ ΔCAGR 、 ΔMDD ）是否同時朝預期方向移動。

3.6.4 分析手法

為支援上述三組對照的實證檢驗，本研究於績效分析模組中實作六類分析手法。各手法對應的驗證目的與第四章對應小節如下：

- (一) 邊際貢獻分析：透過 $\Delta CAGR$ 與 ΔMDD 的差分分布，量化某一構面加入後的邊際效果。例如 F+C 相對於 F-only 的 $\Delta CAGR$ 分布、F+C+V 相對於 F+C 的 $\Delta CAGR$ 與 ΔMDD 聯合分布。
- (二) 敏感度熱力圖：將不同門檻水準的因子交叉比對，以視覺化方式呈現績效隨參數變動的平滑性。若績效僅在極少數參數組合上突出，則可能是資料探勘造成的孤立最佳化；若績效隨參數變動呈現可辨識的區域性變化，則較支持因子效力的真實存在。
- (三) 盒鬚圖分布比較：呈現同一因子組內所有策略的 CAGR 或 MDD 分布。中位數位置反映該組的整體水準，箱體與鬚狀延伸範圍反映組內差異程度，箱體過寬表示即使同屬一組，策略表現仍高度發散，該因子的篩選效果不具穩定性。
- (四) 獲利集中度指標：以赫芬達爾—赫希曼指數 (Herfindahl-Hirschman Index, HHI) 量化單一策略的獲利是否集中於少數個股，並以 HHI 的倒數作為有效貢獻股票數 (Effective N)，高 HHI 或低 Effective N 代表策略績效依賴少數個股，策略的未來重現性存疑。
- (五) Top25%、Top50% 排名穩健性檢驗：依 CAGR 排名取出前 25% 與前 50% 的策略子集，檢視各子集中最高獲利貢獻個股 (Top1) 的出現頻率與貢獻占比。若 Top1 個股在高排名子集中反覆出現且貢獻占比明顯偏高，則該群策略的高績效可能源自離群值而非架構本身的選股能力。
- (六) 子樹固定下的 C 因子趨勢分析：在不固定體質條件時，C 類動態因子的效果容易被體質組合的異質性稀釋，使整體分布差異不明顯。為此固定特定 F 子樹 (例如 ROE 區間 5 至 10、EPS 區間 0 至 2)，在體質條件受控的前提下觀察 C 因子的跨區間績效趨勢。本研究對「相對排序穩健」之判讀，係以各動態因子於不同體質固定條件下的中位數排名為依據：以八個動態因子之中位數排名分為前段 (1-3)、中段 (4-5)、後段 (6-8) 三組，若某動態因子於超過半數的體質固定條件下落於前段，且未在任一條件下落入後段，即視為相對排序穩健。

上述六類手法共同構成本研究的分析工具箱。手法本身並非本研究首創，但將其整合於同一套宣告式引擎之下使所有分析均能基於相同的標準化儲存檔進行，是本研究擴充應用層的具體價值。本節所述之因子挑選、區間切分、對照組設計與分析手法，共同構成本研究的實驗驗證框架。此框架所產出的實證證據將於第四章分兩層呈現：4.3 節以三組對照逐層檢驗 F-C-V 三構面框架的策略有效性，4.4 節以實際批次運算之實測資料檢驗宣告式引擎的工程可行性。

四、實驗結果與分析

4.1 樣本區間與資料來源

本研究以台灣股票市場為實證場域，回測樣本區間為 2000 年 1 月 4 日至 2024 年 12 月 29 日，涵蓋約 25 年的交易日資料。樣本期間橫跨多種市場狀態，包含 2000 年網路泡沫化後的修正期、2008 年全球金融海嘯、2020 年新冠疫情衝擊，以及 2021 至 2022 年的通膨升息環境，使策略在不同景氣階段的表現均納入檢驗範圍。

原始資料取自 TEJ 台灣經濟新報資料庫，透過 TEJ Smart Wizard 擷取後匯入 MySQL 資料庫，由資料存取層統一管理。資料內容涵蓋三類：第一類為個股日頻交易資料，來源為 TEJ 股價資料庫之除權息調整股價，包含開盤價、最高價、最低價、收盤價與成交量；第二類為季頻財務報表資料，來源為 TEJ IFRS 以合併為主簡表（單季），包含本研究使用之每股盈餘、股東權益總額、負債及股東權益總額、營業收入淨額、自由現金流量與本益比等欄位；第三類為大盤指數資料，包含台灣加權股價指數；其中第四章 4.3.1 節用以與策略 CAGR 對照之大盤量級基準，另採同期間台灣加權股價報酬指數（含股利再投資）之年化報酬數值，以與本研究策略之含股利口徑一致。樣本範圍限定為台灣證券交易所上市之普通股，共計涵蓋 1,775 間公司，包含研究期間內已下市之標的。

財務報表資料之時間軸對齊方式依 3.5 節所述之法定公告時程，由底層引擎統一將各類財報對齊至其實質可用的起始日期，並以前推補值方式沿用至下一次財報公告之前。

4.2 因子切分規則

本節將列出各構面因子的具體區間設定與策略空間的展開規模，區間邊界的切分原則已於 3.6.2 節說明，以下直接呈現各構面的具體設定。本次實驗所採用之 F、C 因子為文獻中已證實具有相對較佳實證表現的候選因子，由於本論文提出的回測引擎於設計上已適用於各類因子，因此本章實證之目的為呈現此引擎於特定候選因子集上的績效分析方法論，而非主張所選因子即為最佳績效之組合。

體質構面使用四種因子，各因子依其財務意涵劃分為若干不重疊的區間，合計 14 個區間。ROE 以 5 個百分點為級距劃分五個區間，涵蓋從低獲利至高獲利的完整範圍；EPS 以 0 元作為虧損與否的分界，再以 2 元作為穩定盈餘門檻，區分虧損、微利與穩定獲利三種狀態；FCF Yield（自由現金流除以市值）以 0 作為正負分界，再以 0.05 作為具備充裕自由現金流之門檻；Debt Ratio（負債比率）以 0.35 與 0.55 為分界，分別對應低槓桿、中度槓桿與高槓桿三種財務結構，各因子之具體區間定義彙整於以下表格²。

表 4-1 F 構面因子區間定義

因子名稱 (單位)	區間 1	區間 2	區間 3	區間 4	區間 5
ROE (%)	$(-\infty, 5)$	$[5, 10)$	$[10, 15)$	$[15, 20)$	$[20, +\infty)$
EPS (新臺幣元)	$(-\infty, 0)$	$[0, 2)$	$[2, +\infty)$	—	—
FCF Yield (比率)	$(-\infty, 0)$	$[0, 0.05)$	$[0.05, +\infty)$	—	—
Debt Ratio (比率)	$[0, 0.35)$	$[0.35, 0.55)$	$[0.55, +\infty)$	—	—

動態變化構面（C）以 F 構面的四種因子為基礎衍生跨期變化條件，共八種，編號 C1 至 C8，各條件的基礎因子、條件類型與判斷語意彙整於表 4-2。

² 區間表示法為左閉右開 $[a, b)$ ，即 $a \leq x < b$ 。ROE 區間數值之單位為百分比（%），例如 $[5, 10)$ 表示 $5\% \leq \text{ROE} < 10\%$ 。EPS 之單位為新臺幣元，FCF Yield 與負債比率之區間數值均為小數比率。

表 4-2 C 構面因子區間定義

編號	基礎因子	條件類型	條件語意
C1	ROE	is_highest_q	當季 ROE 為近四季最高值
C2	ROE	rise_q	當季 ROE 較前一季上升
C3	ROE	yoy_gt	當季 ROE 較上年同季上升
C4	Revenue	is_highest_q	當季營收為近五季最高值
C5	Revenue	yoy_gt	當季營收較上年同季上升
C6	EPS	yoy_gt	當季 EPS 較上年同期上升
C7	EPS	ytd_avg_gt_prev_year _same_period_avg	本年至今 EPS 平均高於去年同期平均
C8	FCF	rise_q (窗口為兩季)	當季 FCF 較前兩季上升

各條件類型的計算語意與參數意涵已於表 3-2 定義，C8 之比較窗口設為兩季而非一季係因自由現金流的計算包含資本支出，而資本支出具有不均勻的特性，單季度的大額設備採購或處分即可使 FCF 產生劇烈波動。Piotroski (2000) 在衡量現金流改善時即採年度變化量而非季度比較，因此在此條件中將 FCF 的比較窗口延長至兩季，與此設計邏輯一致，降低資本支出時點造成的短期雜訊。

上述八種條件刻意涵蓋不同類型的成長訊號：C1 與 C4 捕捉指標創歷史區間新高的動態；C2 與 C8 捕捉連續季度的方向性改善；C3、C5、C6 以年增率為基礎衡量同期比較的成長幅度；C7 則以累積平均比較法平滑單季波動。此設計的目的，是讓後續分析（4.3.3 節）得以在固定體質條件下，比較不同類型動態因子的邊際貢獻差異。

估值構面設定兩種固定配置：

- V0：不套用估值門檻，作為基準組。

- V1：當季本益比低於近四季本益比平均，且高於近四季本益比最低值。

V1 的條件語意對應價格落在略低於自身歷史估值水準，但非處於極端壓縮區的相對估值區間。在後續分析中，V0 與 V1 將作為配對對照，用以檢驗在相同的 $F \times C$ 條件下加入估值門檻對 CAGR 與 MDD 的影響方向與幅度。

依上述三構面的設定，系統以自動展開邏輯進行交叉組合，展開結構如第三節中圖 3-2 樹狀圖所示。 $F[1] \times F[2]$ 的組合數推導如下：14 個 F 區間分屬四種因子（ROE 5 個、EPS 3 個、FCF Yield 3 個、Debt Ratio 3 個），每個區間作為 $F[1]$ 時，其 $F[2]$ 可選擇不同欄位的任一區間或不搭配 $F[2]$ （即 None）。以 ROE 的任一區間為例， $F[2]$ 候選包含 EPS（3 個）、FCF Yield（3 個）、負債比率（3 個）加上 None，共 10 種選擇；ROE 的 5 個區間合計產生 50 組。同理，EPS、FCF Yield、負債比率各 3 個區間，每個區間對應 12 種 $F[2]$ 選擇，三者合計 108 組。F 組合總數為 $50 + 108 = 158$ 組。

每組 F 組合再與 9 種 C 配置（C1 至 C8 加上不套用 C）及 2 種 V 配置交叉，合計 $158 \times 9 \times 2 = 2,844$ 組策略。其中，回測期間內換股次數（依月度換股頻率計算）不滿五次之策略予以排除，將門檻設為五次係因經過測試後發現當換股次數低於五次時，部分策略因僅有極少數交易樣本而出現異常極端的績效數值，不適合納入後續的分布分析與穩健性檢驗，因此排除後將共計 2,084 組的策略納入後續績效分析，占原始策略空間的 73.3%。

4.3 實驗結果與分析

本節依 3.6.3 節所定義的三組實驗對照逐步呈現 2,084 組策略的實證結果。分析順序為：先以整體策略空間為對象，檢視系統在批次回測情境下的實用性，並檢驗高績效策略的獲利來源是否具備分散性（4.3.1）；再依 F 構面拆解體質因子的單層與雙層篩選效果（4.3.2）；接著固定體質條件，檢驗 C 構面各動態因子的跨體質穩健性（4.3.3）；最後以 V0 與 V1 的配對對照，評估估值門檻對報酬與風險的影響方向（4.3.4）。

4.3.1 至 4.3.4 所呈現之四項分析方法，於任一 F-C-V 配置下均可適用：4.3.1 以個股貢獻指標與 Effective N 判讀策略獲利之分散程度；4.3.2 以單層、雙層分布之收斂對比辨識體質構面之區辨能力；4.3.3 以體質條件由不限至子樹逐層固定，辨識動態因子之條件性效益；4.3.4 以 $\Delta CAGR$ 與 ΔMDD 之四象限聯合分布，判讀估值門檻是否達成「報酬下降換得風險下降」之有利交換。本章以本研究因子集為示範，呈現上述方法之具體運作；於其他因子集配置下亦可直接套用同一方法。

各節在分析時對其他構面之控制方式不同，反映該節欲隔離之觀察對象有別。

4.3.1 不對任何構面施加固定條件，直接呈現全策略空間之整體分布，作為後續分析的可信前提。4.3.2 為隔離體質構面本身的效果，將 C 構面固定為不套用、V 構面固定為 V0，使觀察到之績效差異僅來自 $F[1] \times F[2]$ 雙層篩選。4.3.3 為觀察動態因子之跨體質穩健性，將 V 固定為 V0，體質條件則由不限制、單層、雙層至固定子樹逐步推進，以辨識動態因子之相對排序在不同體質背景下是否維持一致。4.3.4 為評估估值門檻之邊際影響，以同一 $F \times C$ 組合下 V1 與 V0 之配對差值（ $\Delta CAGR$ 、 ΔMDD ）作為比較基準，使估值構面之效果與前兩層之選股結果分離。

4.3.1 策略展開與整體績效摘要




圖 4-1 分析範圍示意圖：章節分析對象為全部 2,084 組策略

為判讀策略獲利之分散程度，避免高排名策略之高報酬源自少數個股之極端表現，以下以納入分析的 2,084 組策略為對象（展開規模見 4.2 節），先以熱力圖呈現整體分布的快速定位結果，再以排名第一之策略為例展示績效分解深度，最後以個股貢獻度與集中度指標，檢驗排名前段策略的獲利分散性。

圖 4-2 自 2,084 組策略中依 CAGR 由高至低擇取前 10 名，以熱力圖同時呈現 CAGR、年化夏普值、最大回檔與勝率四項指標。色階依各指標在前 10 名內的 z-score 著色，數值則為原始指標值。此圖由 report_analysis.py 模組依使用者指定之排序指標與呈現筆數自動產出，使用者得以不逐一開啟個別報表，便快速比較跨指標的相對表現差異。




圖 4-2 Top 10 策略績效熱力圖

熱力圖呈現三項特徵。第一，前 10 名策略的動態因子皆採 C1（ROE 近四季最高）、估值門檻皆套用 V1，可見此 $C \times V$ 組合於整體策略空間中具有較強的篩選效果。第二，CAGR 最高之策略達 33%（作為量級對照，同期間台灣加權股價報酬指數之年化報酬約為 6%），對應夏普值為 11.43、最大回檔為 -0.36、勝率為 0.54；夏普值最高之策略則達 18.00，但其最大回檔為 -0.52，遠深於 CAGR 排名第一者。可見高報酬與低風險不必然並存，使用者應依風險偏好挑選組合。第三，由於 F[1] 與 F[2] 在架構中的篩選順序具有明確意義（F[1] 先排除、F[2] 再精選），部分策略因 F[1] 與 F[2] 的指派順序不同而出現相近的績效（例如第 1 名與第 2 名）。

確認系統能有效定位候選策略後，下一步需檢視個別策略的績效細節。圖 4-3 以 CAGR 排名第一之策略為例（對應 fcv_experiment_spec.json 中因子組合為 F[1]=

ROE < 5、F[2] = FCF Yield $\geq$ 0.05、C = C1、V = V1)，呈現其資產曲線、回檔走勢、月報酬分布、持股數量變化與年度報酬分解。



圖 4-3 單一策略資產曲線與年度報酬分解

該策略在 25 年間的累積報酬並非均勻增長，2009 年與 2020 年前後出現明顯的加速區段，而 2008 年與 2022 年則伴隨較深的回檔。年度報酬分解則顯示部分年度報酬超過 40%，亦有年度為負值，績效在時間維度上分布並不均勻。為釐清高報酬年度的獲利組成，圖 4-4 將該策略各年度的獲利拆解至個股層級，呈現每年度貢獻度最高的前 10 檔個股與其餘個股的加總貢獻。



圖 4-4 單一策略年度股票貢獻度分布

各年度的主要貢獻個股並不固定，例如 2009 年貢獻最高的個股在 2015 年並未出現於前 10 名，而 2020 年的主要貢獻者又是另一批標的。此輪替現象顯示策略的選股結果隨市場狀態與財報更新而動態調整，並非鎖定特定標的長期持有。同時，即使在報酬較高的年度，單一個股的貢獻度亦未占據壓倒性比例，整體獲利由多檔個股在不同年度分別累積貢獻而成，而非單一個股之極端報酬所驅動。此觀察初步排除了單一策略層級的個股集中疑慮，但尚不足以推論至整體策略集合：若多數高績效策略的獲利恰好都集中於相同的少數個股，則所觀察到的高報酬可能僅反映特定個股在回測期間的極端表現，而非 F-C-V 架構本身的篩選能力。

為檢驗此疑慮，本研究取 CAGR 前 25%、前 50%（依四分位數分界）兩個策略集合，分別統計各策略中貢獻最高個股（Top1）的出現頻率與貢獻占比。此處貢獻占比定義為單一個股在該策略回測期間內的累積正報酬，占該策略全部累積正報酬之比率。圖 4-5 呈現前 25% 策略集合中 Top1 個股的出現頻率分布。




圖 4- 5 CAGR 前 25% 策略之 Top1 貢獻個股出現頻率（前 20 名）

前 25% 的策略集合中，佰研（3205）為最常成為 Top1 貢獻個股的標的，共出現 14 次；其次為聯鑫（3219）11 次與全新（5215）10 次。出現頻率的分布呈遞減但非陡降的型態，前 20 名個股的出現次數介於 2 至 14 次之間，無任一個股壟斷多數策略之 Top1。圖 4-6 則呈現各個股成為 Top1 時，其累積正報酬占該策略全部累積正報酬之比率。




圖 4- 6 CAGR 前 25%策略之 Top1 貢獻個股之報酬貢獻占比（前 20 名）

佰研成為 Top1 時，其平均貢獻占比約 1.6%，意味著即使作為策略中貢獻最高者，對整體獲利的影響仍屬有限。前 25% 集合中所有曾擔任 Top1 之個股，其平均貢獻占比的最大值亦未超過 1.7%，策略績效並非由任一單一標的驅動。將觀察範

圍擴大至 CAGR 前 50%（圖 4-7、圖 4-8），集中度的變化可作為前段與中段策略的品質對比依據。




圖 4-7 CAGR 前 50% 策略之 Top1 貢獻个股出現頻率（前 20 名）




圖 4-8 CAGR 前 50% 策略之 Top1 貢獻个股之報酬貢獻占比（前 20 名）

佰研的 Top1 出現次數從前 25% 集合的 14 次增至前 50% 集合的 29 次；同期間聯鑫的 Top1 次數則維持 11 次，佰研與第二名的差距因而拉大。額外的 15 次全部來自排名 25-50% 之間的中段策略，顯示中段策略對佰研之依賴高於前段策略。協益（5356）於前 50% 集合中有 7 組策略以其為 Top1，其平均貢獻占比達 4.3%，高於前 25% 集合中任一 Top1 个股之水準。前段擴大至中段的過程中，出現對特定個

股依賴較深之策略子群，其穩健性相對較低，亦間接佐證前 25% 策略的獲利品質優於中段策略。

上述分析以 Top1 個股的頻率與占比為切入點，但尚未呈現獲利在更多個股間的完整分布型態。圖 4-9 以累積正貢獻占比曲線補充此面向：依個股貢獻度由高至低排列，累加至前 20 檔個股，分別繪製前 25% 與前 50% 策略集合的中位數、第 25 百分位與第 75 百分位三條曲線。




圖 4-9 累積獲利貢獻曲線：前 25% 與前 50% 策略集合之比較

前 25% 策略集合的三條曲線呈現較為緊密且斜率一致的上升趨勢，不論策略處於該集合內的哪一個分位，其獲利在個股間的分布型態皆相近，不存在少數策略因極端集中而拉高整體表現的現象。反觀前 50% 策略集合，第 75 百分位曲線在前 5 檔個股即出現較陡的上升，與第 25 百分位曲線之間的帶寬明顯加大，代表中段策略中存在獲利高度集中於少數個股的策略子群。

累積貢獻曲線呈現的是個股層級的分布形狀，為進一步將集中度量化為單一可比較的數值，圖 4-10 以 Effective N（定義為 HHI 的倒數，數值越低代表獲利越集中於少數個股）分別繪製前 25% 與前 50% 策略集合的金鬚圖。




圖 4- 10 Effective N 盒鬚圖：前 25% 與前 50% 策略集合之比較

兩組策略集合的中位數皆落在約 350 至 370 之間，顯示多數策略的獲利來源相當於分散在數百檔個股之間，並未呈現高度集中的型態。但前 50% 策略集合的下四分位數明顯低於前 25%，且低值方向的離群點分布更為密集，代表中段策略中存在一群 Effective N 偏低、獲利集中度較高的策略子群。此結果與前述 Top1 貢獻占比及累積貢獻曲線的觀察方向一致：前 25% 策略的獲利分散性整體優於前 50%，其績效較不易因單一個股的表现變化而產生劇烈波動。

透過代表性策略的整體績效與 Top1 個股貢獻統計，可追溯績效的形成來源。在前 25% 策略集合中，雖存在少數個股反覆成為 Top1 的現象，但其 Top1 占比平均上限約落在 1.7%，獲利未呈現由單一個股壟斷的高度集中型態。當策略集合擴大至前 50% 時，Top1 占比平均出現更高尖峰(例如協益達 4.3%)，代表納入更多中段策略後，獲利集中於少數標的的風險上升。年度分解與個股貢獻集中度兩項指標所構成之分散性判讀方法，使策略績效的可解釋性與穩健性納入評估，亦可套用於其他因子集配置之分散性檢驗；此分析結果亦作為後續討論策略可移轉性與過度配適風險的重要依據。既然整體架構具備篩選能力且獲利來源具有分散性，接下來的問題便是各構面分別貢獻了多少篩選效果，以及哪些因子的邊際貢獻最為穩健，此即 4.3.2 至 4.3.4 節的分析重點。

4.3.2 體質構面分析




圖 4-11 分析範圍示意圖：本節分析對象為體質構面的單層與雙層篩選效果

承前節對整體分布之確認，以下進一步拆解體質構面，辨識體質構面之區辨能力並檢驗雙層篩選之收斂效果。具體上回應兩個問題：第一，F 區間在僅使用單層篩選 (F[1] only) 時，各區間的績效分布是否已足以區辨出優劣？第二，加入第二層因子 (F[2]) 後，績效分布是否出現有意義的變化，使雙層篩選的設計取得實證上的支持？

圖 4-12 以盒鬚圖呈現各 F[1] 區間在不套用 F[2] (F[2] = None)、涵蓋所有 C 與 V 配置下的 CAGR 分布，各區間依中位數由高至低排列。




圖 4-12 單層體質因子 CAGR 分布盒鬚圖 (F[2] = None，涵蓋所有 C/V)

從圖中可見排名前段與後段的區間之間存在明確的績效落差，FCF Yield ≥ 0.05 的中位數約為 0.17，為所有區間中最高，其次為負債比率 ≥ 0.55 (約 0.16)、負債

比率 0–0.35（約 0.14）、EPS 0–2（約 0.14）與 ROE < 5（約 0.13）。傳統財務分析將 ROE < 5 視為獲利能力偏低的區間，但在本研究的架構下，此區間作為 F[1] 時的中位 CAGR 仍位於前段；4.3.3 節將於加入動態變化構面後進一步觀察此現象。相對地，ROE 5–10、ROE 10–15 與 EPS < 0 等區間的中位數落在 0.02 至 0.05 之間，與前段區間的差距達到 10 個百分點以上。上述分析的結果顯示單層體質因子已具備初步的區辨能力：選擇不同的 F[1] 區間，確實會導致策略績效分布的系統性差異。

但即使是中位數最高的前五個區間其四分位距仍然偏大。以 FCF Yield $\geq$ 0.05 為例，第 25 百分位與第 75 百分位之間的距離約為 8 個百分點，且存在離群值使 CAGR 最高可達 0.30。此離散現象意味著，僅以單一因子篩選時，同一區間內仍混雜績效差異甚大的策略組合；單層篩選提供的是方向性的傾向，而非穩定一致的結果。若要進一步收斂績效分布、提高篩選的精確度，需要加入第二層因子加以區隔。

圖 4-13 以熱力圖呈現 F[1] $\times$ F[2] 交叉組合下的平均 CAGR，條件固定為不套用 C（C = None）且不套用估值門檻（V = V0），以隔離體質構面本身的效果。橫軸為 F[2] 區間（含 None），縱軸為 F[1] 區間，色階對應平均 CAGR。圖中白色格位為同欄位自配之組合，已依 4.2 節所述之展開規則排除。




圖 4-13 F[1] × F[2] 雙層體質因子平均 CAGR 熱力圖 (C = None, V = V0)

熱力圖呈現兩個現象。第一，同一 F[1] 區間搭配不同 F[2] 條件後，平均 CAGR 出現明顯的變動幅度。以負債比率 ≥ 0.55 為例，搭配 FCF Yield ≥ 0.05 時平均 CAGR 位於色階高值端（圖中黃色區域），但搭配 ROE 10–15 或 ROE 15–20 時則降至色階中段，顯示 F[2] 的選擇對最終績效具有實質影響，而非僅是重複篩選。第二，色階高值端的格位大多集中在圖 4-12 中表現較佳的因子所構成的交叉區域，例如負債比率區間搭配 FCF Yield 區間、EPS 0–2 搭配 FCF Yield ≥ 0.05 等組合。換言之，表現較佳的策略組合傾向由兩個各自表現良好的因子搭配而成。

但此傾向並非絕對，部分「強強組合」的平均 CAGR 並未顯著優於任一因子單獨使用，甚至偶有低於 F[1] 單層中位數者。可見因子疊加並不必然產生加乘效果，因子間的交互作用並非簡單的加法關係。

反向觀察色階高值端格位，其 F[1] 與 F[2] 幾乎都來自單層分析中排名前段的區間。排名後段者即使搭配強勢 F[2]，平均 CAGR 仍難以推升至高值端。

此不對稱性支持的實務推論是：雙層篩選的價值不在於保證任意組合都能提升績效，而在於協助使用者從本來就具方向性優勢的單層區間中，再以 F[2] 篩選出績效更穩定之子群。

單層體質因子已能將 14 個區間區分為績效偏高與偏低兩群，但前段區間內部的離散程度仍大，單一因子的篩選精確度有限。加入 F[2] 後，同一 F[1] 區間內的績效分布因 F[2] 的不同而產生有意義的差異，使高績效子群更容易被辨識。但排名前段的雙層組合多由兩個各自表現良好的因子搭配而成，兩者疊加後的績效並不必然優於任一因子單獨使用時的結果，因子間的交互作用並非簡單的加法關係，需要透過系統性的批次實驗才能觀察。此觀察對應宣告式設計的實務價值：使用者僅需在設定檔中列出因子與區間，系統即自動展開所有合法的 F[1] × F[2] 組合並產出比較圖表，無需逐一撰寫篩選邏輯。

上述以單層、雙層分布之收斂對比辨識區辨能力之方法，亦可直接套用於其他因子集配置之區辨能力檢驗。F-C-V 架構中尚未檢驗的是動態變化構面（C）在不同體質組合下是否具備穩健的邊際貢獻，為接下來要分析之內容。

4.3.3 動態變化構面之跨體質穩健性分析




圖 4-14 分析範圍示意圖：動態構面

為辨識動態因子之條件性效益，本節以體質條件由不限至子樹逐層固定，檢驗各動態因子之相對排序是否於不同體質背景下維持一致。所謂跨體質穩健性，指特定動態因子的相對排序在多種體質固定條件下維持一致的程度。以下以各動態因子於體質固定條件下的平均 CAGR 相對排序為主要判讀依據，不採統計顯著性檢定，沿用 3.1.4 節所述之分析準則。此處所論之邊際貢獻，係指控制體質後動態因子之間的平均 CAGR 差異，並非迴歸框架下之偏迴歸係數。

分析範圍限定於 C 構面，依四個層次由粗至細推進：先檢視不限體質條件下的整體分布；再以單層體質固定條件觀察動態因子之相對排序；繼而以雙層體質固定條件檢視交互作用；最後以特定子樹進行敏感度檢驗。




圖 4-15 不限 F 條件下各動態因子之 CAGR 分布盒鬚圖

圖 4-15 呈現於 V0（不套用估值門檻）下、不限體質組合的各動態因子 CAGR 分布。八組盒鬚的中位數彼此接近、邊界相互重疊，離群值之分布範圍亦未顯示明顯差異。若直接以單一動態條件對所有策略分組，體質組合的異質性會稀釋動態因子的相對效益。後續分析需將體質條件納入控制，方能辨識動態因子本身的貢獻。




圖 4-16 單層體質因子組合於各動態因子下之平均年化報酬率

將分析改以單層體質因子（即僅固定 F[1] 或僅固定 F[2] 之單一區間，不採 F[1] × F[2] 雙層組合）為固定條件後，C1 至 C8 的相對表現出現明顯區隔。圖 4-16 以折線方式呈現各單層體質因子下動態因子的平均 CAGR：C1、C3、C6 對應之折線多

落在較高位置；以八個動態因子之中位數排名分為前段（1-3）、中段（4-5）、後段（6-8）三組計，C1、C3、C6 於超過半數的單層體質固定條件下落於前段，且未在任一條件下落入後段，符合 3.6.4 節所定義之穩健性判準；C7、C8 對應之折線則普遍落在較低位置。C1（ROE 近四季最高）、C3（ROE 較上年同季上升）、C6（EPS 較上年同期上升）三者皆衍生自財報層面直接衡量企業獲利能力之指標（ROE 或 EPS），相對於現金流量類（FCF Yield）與資本結構類（負債比率）之衍生條件，於相對排序上明顯領先。控制體質條件後，動態因子之間的差異得以辨識，支持 F-C-V 架構先固定體質、再評估動態的分析順序：以單一動態因子作為篩選核心時，C1、C3、C6 為較具一致表現的候選。




圖 4-17 $F[1] \times F[2]$ 雙層體質因子組合於各動態因子下之平均年化報酬率熱力圖

圖 4-17 將體質條件擴展至 $F[1] \times F[2]$ 雙層組合，呈現每一個雙層組合在各動態因子下的平均 CAGR。色階高值端集中於熱力圖的特定區塊：對應的體質組合以 EPS 0-2、ROE 5-10、負債比率 ≥ 0.55 等較佳組合為主，動態因子則為 C1、C3、C6；其他位置的色階明顯較低。排名居前的策略多由排名前段的體質組合搭配排名前段的動態因子構成，但兩者的組合並未全部達到相同水準。色階分布顯示動態

因子的效益具有條件性，亦即同一動態因子在不同體質背景下表現有別，方能於特定體質背景下完整顯現其貢獻。




圖 4-18 固定不同子樹條件之動態因子 CAGR 分布

除上述三類整體性比較外，系統亦支援使用者將分析鎖定於特定子樹，以更細緻的條件檢驗動態因子之穩健性。圖 4-18 並列呈現兩組子樹的對照結果：第一組固定 $F[1] = \text{ROE } 5-10$ 、 $F[2] = \text{EPS } 0-2$ ，第二組改以 $F[1] = \text{ROE } 5-10$ 、 $F[2] = \text{FCF Yield} \geq 0.05$ ，其餘條件保持一致。在 $\text{ROE } 5-10 \times \text{EPS } 0-2$ 子樹下，C1（ROE 近四季最高）之 CAGR 中位數明顯高於其他動態因子，分布上限延伸至更高之 CAGR 水準，反映該動態因子於指定體質背景下對策略表現具有加成效果。將第二層體質因子由 EPS 0-2 替換為 $\text{FCF Yield} \geq 0.05$ 後，C1 仍維持相對較佳的中位數位置，但 C8 之 CAGR 分布明顯下移，與 EPS 子樹的結果產生落差，顯示同一動態因子搭配不同體質因子時邊際貢獻並非固定。此一觀察與 4.2 節所述 C8 採兩季窗口之設計考量相呼應，亦提示 C8 在 FCF 衍生條件下的敏感度有別於其他動態因子。子樹固定分析使使用者得以於指定體質背景下檢驗特定動態因子的敏感度，作為策略選用前的驗證步驟。

上述四個層次的分析指向一個結構性現象：動態因子的相對效益在不限體質條件下難以辨識，但在納入體質控制後，C1、C3、C6 於多數體質背景下取得較高的平均 CAGR，並於固定子樹的細部檢驗中維持相對優勢。動態因子的貢獻並非獨立於體質之外，而是與體質條件存在交互作用，必須在控制體質的前提下才能辨識。

上述觀察與 3.2 節所述 F-C-V 遞進邏輯之設計初衷一致。若採傳統將體質與動態合為單層的多因子做法，動態因子的價值將與體質的篩選效果混雜於同一層，難以分離。F-C-V 架構透過先固定體質、再展開動態的層次設計，使動態因子的條件性特徵得以系統化呈現，並可依需要細化至特定子樹進行敏感度檢驗；此一辨識方法亦適用於其他動態因子集之條件性檢驗。動態變化構面的獨立切分使本研究得以將分析範圍由靜態多因子框架延伸至跨期動態維度，並透過跨體質穩健性分析提供具體實證支持。

4.3.4 估值條件納入影響




圖 4-19 分析範圍示意圖：估值構面

為判讀估值門檻是否達成「報酬下降換得風險下降」之有利交換，以下以同一 $F \times C$ 組合下 $\Delta CAGR$ 與 ΔMDD 之四象限聯合分布作為判讀工具。估值構面 (V) 的設計目的有別於體質構面與動態變化構面。後二者透過正向篩選提升勝率與報酬，前者則以本益比門檻控制進場估值風險，目的為犧牲部分潛在報酬以換取下檔保護。以下評估 V1 條件納入後之影響時，同時納入風險與報酬兩個維度，而非單以 CAGR 為判讀依據。於同一 $F \times C$ 組合下，逐對計算 V1 與 V0 之 CAGR 差值與 MDD 差值。前者定義為 $\Delta CAGR = CAGR_V1 - CAGR_V0$ ，後者為 $\Delta MDD = MDD_V1 - MDD_V0$ 。本研究之 MDD 採負值表示回檔深度（如 -0.36 代表最大回檔 36%），故 ΔMDD 為正值代表 V1 之最大回檔較淺、風險下降。V1 之操作定義為當季本益比相對於該標的近四季本益比序列之相對位置進行篩選，細節參 3.3.3。

分析依四個層次推進：先從風險與報酬之雙軸觀察整體分布，繼而檢視 V 對 F、V 對 C 之條件性差異，最後以指定子樹進行細部檢驗。




圖 4- 20 V0 與 V1 本益比條件下之 Δ CAGR 分布

圖 4-20 以 Δ CAGR 量化 V1 相對於 V0 的邊際影響。 Δ CAGR 多落於負值區段，多數策略在納入 V1 後 CAGR 反而下降。原因可由動態條件之邏輯解釋：C 構面已將篩選對象鎖定於通過動態因子篩選之標的，於該前提下再以本益比門檻進場，常因標的之估值已偏高而錯失進場時點，進場保守化壓縮獲利空間。V1 並非單向提升報酬之通用濾網。




圖 4- 21 Δ CAGR 與 Δ MDD 聯合分布散布圖

獲利下降是否換得對應之風險下降，需同時納入 MDD 變動量方能判讀。圖 4-21 以 Δ MDD 為橫軸、 Δ CAGR 為縱軸繪製散布圖，N = 1,030 組可比較策略呈現於

圖中。四個象限對應四種狀態：報酬上升兼風險下降之理想結果占 11.1%，報酬下降兼風險下降之預期結果占 10.0%，報酬上升兼風險上升之風險偏好結果占 20.2%，報酬下降兼風險上升之非預期結果占 58.7%。整體而言，僅 21.1% 之策略落於風險下降之兩個象限，近六成策略落於獲利下降兼風險上升之區段，與 V1 之原始設計意圖相反。上述結果不否定 V1 之設計價值，而是顯示其適用範圍受 F 與 C 之條件限制；後續 V 對 F 與 V 對 C 之分析將辨識其具體適用條件。




圖 4-22 V0 與 V1 於不同體質因子下之 CAGR 分布

圖 4-21 顯示 V1 僅於少數策略產生預期效益，因此進一步檢視 V1 於何種體質背景下才能產生預期效益。圖 4-22 以體質因子區間分組，比較 V0 與 V1 之 CAGR 分布。V1 之邊際影響具明顯條件性。於 ROE < 5、ROE 5–10 與 EPS 0–2 之區間，V1 不顯著改變 CAGR 分布，中位數差異不大；於 EPS < 0、ROE ≥ 20 與 FCF Yield < 0 之區間，V1 較常導致 CAGR 分布下移，其中 EPS < 0 區間之中位數於納入 V1 後由約 10% 下降至約 -2%，下移幅度最為顯著。前述現象可由本益比指標之適用性解釋：高 ROE 族群多已被市場給予較高估值，本益比門檻於該背景下反向篩除原可進場之時點；EPS 為負之區間本益比指標失真，門檻條件之適用性低；FCF 偏弱族群之獲利品質較低，估值門檻未能補強篩選效果。本觀察與圖 4-21 之聯合分布結果相呼應，少數能同時達成風險下降之策略多落於 V1 條件與該族群基本面相容之區段。




圖 4-23 V0 與 V1 於不同動態因子下之 CAGR 分布

同樣的觀察邏輯適用於動態因子。圖 4-23 將策略依 C 類別分組後，分別比較 V0 與 V1 之 CAGR 分布。V1 於各 C 類別下普遍導致 CAGR 中位數下降，但下降幅度依 C 類別而有差異。C1（ROE 近四季最高）之 V1 中位數較 V0 略低，但 V1 分布上限延伸至接近 V0 之水準，整體影響相對溫和；C2（ROE 較前一季上升）之 V1 影響亦相對輕微。C3、C6、C7 三類於 V1 下中位數明顯下降，且分布下緣延伸至更深之負值區段，C8 於 V1 下亦呈中位數下降之現象。值得對照的是，4.3.3 辨識為較具一致表現之 C1、C3、C6 於本節呈現分歧結果：C1 於 V1 下表現相對穩定，C3 與 C6 則受 V1 影響較大，顯示 V1 之適用性需進一步結合特定 $F \times C$ 子樹方能判讀。




圖 4-24 指定子樹條件下之 V0 與 V1 CAGR 分布對照

系統並支援使用者於指定子樹下檢視 V1 納入前後之影響。為與 4.3.3 節已展開之子樹固定分析保持方法論一致性，本節延續以 $F[1] = \text{ROE } 5-10$ 為固定條件，避免子樹基準在各節之間任意變動。圖 4-24 並列呈現各 C 類別下 V0 與 V1 之 CAGR 分布；子樹固定後 CAGR 量級較整體分析顯著縮小，故以三位小數呈現中位數差異。與整體分析結果相反，於該子樹下 V1 對多數 C 類別呈現加分效果。C1 之 V1 中位數由約 0.005 上升至約 0.036，C2 由約 0.005 上升至約 0.029，C3 由約 0.023 上升至約 0.033；僅 C8 於 V1 下略有下降，C6 之 V1 與 V0 中位數則大致持平。該結果直接支持本節之核心發現：於 ROE 5-10 區間搭配 ROE 衍生之動態因子（C1、C2、C3）下，再配合本益比門檻進場可同時降低風險並維持或提升 CAGR。子樹固定方式提供使用者於指定基本面背景下評估 V1 適用性的工具，避免將整體統計結果直接套用至個別策略。

上述四個層次的分析指向一個結論：V1 並非單向提升報酬或單向降低風險之通用濾網。在追求動態成長之策略前提下加入本益比進場條件，多數策略因保守化而獲利下降，其中僅約 21% 策略同時取得風險下降之效果，近六成策略反而落於獲利下降兼風險上升之非預期區段。V1 之邊際效益具明顯條件性，於不同 ROE、EPS、FCF Yield 區間之適用性差異甚大，於不同動態因子下亦呈現分組差異。具

體而言，於 ROE 5–10 區間搭配 C1、C2、C3 等 ROE 衍生之動態因子時，V1 可同時降低風險並維持或提升 CAGR。其他多數條件下 V1 反向影響策略表現。後續策略選用上，V1 不應視為通用之風險控管工具，而應依特定 F 與 C 之搭配條件選擇性套用。

從架構層面，上述觀察反向支持 F-C-V 將估值構面獨立切出之設計。估值條件之邊際效益高度依存於前兩層之選股結果，若將估值條件與其他因子合併於單層處理，其條件性效益將與其他效應混雜，無從分離判讀。本研究透過將 V 構面獨立為一階分析維度，使審慎進場之效益可在跨體質、跨動態兩個維度上分別檢驗，並能藉子樹固定進一步辨識 V1 之具體適用範圍。 $\Delta CAGR$ 與 ΔMDD 之四象限聯合分布所構成之雙軸判讀方法，亦可套用於其他估值條件之效益辨識。

4.3.1 至 4.3.4 四節依 3.6.3 所定義的 F-only、F+C 與 F+C+V 三組對照，逐層檢驗 F-C-V 架構在 2,084 組策略空間上的實證表現。四節的觀察共同指向一項方法論意涵：因子的邊際貢獻於多數情形下並非獨立於其他構面之外，而是與上下層條件的設定存在明顯交互作用。4.3.1 確認系統能於大規模策略空間中定位排名前段之策略，且前 25% 策略集合之獲利來源具備跨個股、跨年度之分散性，使後續分析具備可信前提。4.3.2 顯示單層體質因子已具方向性區辨能力，加入 F[2] 後分布可進一步收斂；惟兩個各自表現良好之因子疊加並不必然產生加乘效果，因子間之交互作用須透過系統性批次比較方能辨識。4.3.3 指出動態因子之相對效益於不限體質條件下難以辨識，於體質受控之子樣本中 C1、C3、C6 取得較高之平均 CAGR，並於子樹固定下維持相對優勢。4.3.4 顯示估值門檻 V1 並非單向之風險控制工具，僅 21.1% 之策略同時取得風險下降之效果，其適用範圍受 F 與 C 之具體搭配條件限制。

上述四項發現之共同意涵在於體質、動態與估值三類因子之邊際貢獻均具備條件性，而非獨立可加總之模組。本研究得以將此條件性以可視化、可審計之方式呈現，係源自宣告式設計所支撐之批次展開機制與標準化儲存格式。若採指令式方式逐案撰寫策略腳本，本節所呈現之跨子樹比較、跨構面熱力圖與配對對照分析將難

以在統一基準下完成；換言之，本節之分析能力本身即直接體現宣告式架構於工程層面之具體價值，亦對應 3.1.3 節所述系統工程驗收標準中之彈性擴充與可重現性兩項要求。

須說明者，本節之實證結果記錄 F-C-V 架構於台灣股市 2000 至 2024 年樣本期間之表現，其驗證對象為宣告式系統作為實證工具之可行性，並非用以推導可推廣之選股法則或具體投資建議。各構面之邊際貢獻亦會因樣本期間、市場狀態與因子定義而異，後續研究若以本研究之系統為基礎延伸測試其他因子集或市場樣本，應視為此架構之延伸應用。

4.4 系統運算效能評估

以下對應 3.1.3 節所定義之三項系統工程驗收標準，以實際批次運算的觀察結果，檢驗本研究所建構之宣告式引擎在工程層面的可行性。對應的實證評估包括批次運算的規模與耗時、所採行優化機制的實際角色，以及驗收標準各項在實作層面的滿足情況。

4.4.1 批次運算規模與耗時概況

本研究之批次回測涵蓋 2,844 組策略，於 2000 至 2024 年共計約 25 年的歷史樣本上執行，所對應之資料規模包含 1,775 檔個股之日頻交易資料與季頻財務報表資料。執行環境之硬體與軟體規格彙整於表 4-3。

表 4-3 實驗執行環境規格

項目	規格
處理器	AMD Ryzen 7 7700 (8 實體核心 / 16 邏輯執行緒，基本頻率 3.8 GHz)
記憶體	63.2 GB
作業系統	Windows 10
Python 版本	3.10.0

主要相依套件	pandas、numpy
--------	--------------

完整批次於上述環境下執行所需之總時間為 3,683.0 秒（約 61.4 分鐘）。表 4-4 則將執行流程拆解為條件解析、批次展開、策略預篩、回測執行、結果儲存五個階段，呈現各階段於總時間之占比，使工程效能瓶頸的分布得以辨識。

表 4-4 批次回測各階段耗時統計

階段	工作	耗時（秒）	占總時間比例
條件解析	JSON 設定檔解析、條件函式生成	0.70	0.0%
批次展開	$F[1] \times F[2] \times C \times V$ 自動展開	184.86	5.0%
策略預篩	換股次數門檻過濾、排序	896.26	24.3%
回測執行	月度換股回測、績效指標計算	2,112.54	57.4%
結果儲存	持股軌跡、交易明細、績效指標匯出	387.25	10.5%
合計	—	3,683.0	100.0%

階段分布結果呈現兩項觀察。其一，回測執行階段占總時間 57.4%，加上其前後緊鄰的策略預篩（24.3%）與結果儲存（10.5%），三項合計約 92%，為本研究批次運算的主要負擔。其二，條件解析（0.0%）與批次展開（5.0%）兩階段相加僅占 5.0%，意味著宣告式介面的解析與三構面架構的自動展開本身在工程上極為輕量，不會成為執行流程的瓶頸。

4.4.2 運算效能優化機制的角色

3.5 節說明的兩項主要優化機制為跨策略共用之布林遮罩快取，以及向量化的條件判斷處理。本研究批次回測於展開階段產生 2,844 組策略組合，預篩後保留

2,084 組進入回測。在此規模下，F[1] 層條件因被多組策略共享，平均重複使用次數為 203 次、最高 216 次。為避免相同 F[1] 條件之中介結果在不同策略間反覆計算，本研究於 condition_factory.py 中設計快取機制：當同一條 F[1] 條件首次被計算後，其結果以條件鍵值為索引保存於記憶體；後續策略若需使用相同 F[1] 條件，直接由快取讀取。

為釐清快取機制於本研究批次規模下之實際貢獻，於啟用與停用快取兩種設定下分別完整執行同一份實驗規格檔，並逐階段記錄耗時。兩種設定下展開後策略數量均為 2,844 組、預篩後均為 2,084 組，F[1] 條件之平均重複次數同為 203 次、最高 216 次。表 4-5 整理兩種設定下五階段之耗時比較：啟用快取時總執行時間為 3,683.0 秒，停用快取時為 3,772.4 秒，差距 89.4 秒（約 2.4%）。差距主要來自策略預篩、回測執行與結果儲存三個階段；條件解析與批次展開階段差距均小於 7 秒，落於重複執行之自然變異範圍。

表 4-5 啟用與停用快取設定下五階段耗時對照

階段	使用快取	不使用快取	差異（停用-啟用）
條件解析	0.70 秒	0.72 秒	+0.02 秒
批次展開	184.86 秒	178.50 秒	-6.36 秒
策略預篩	896.26 秒	919.72 秒	+23.46 秒
回測執行	2,112.54 秒	2,155.95 秒	+43.41 秒
結果儲存	387.25 秒	413.71 秒	+26.46 秒
總計	3,683.0 秒	3,772.4 秒	+89.4 秒（2.4%）

承上述對照觀察，本研究於啟用快取設定下另記錄完整批次回測之記憶體佔用以說明系統當前規模之承載狀態與擴張上限。批次回測各階段記憶體佔用以駐留記

憶體（resident set size，以下簡稱 RSS）與 Windows 程序歷史峰值（peak working set，以下簡稱 peak）兩項指標記錄，整理如表 4-6。批次起始時 RSS 為 0.06 GB；載入 1,775 家上市公司 × 5,943 個交易日之底層資料矩陣後，RSS 上升至 10.92 GB，peak 達 12.81 GB；經 $F[1] \times F[2] \times C \times V$ 四構面展開後，RSS 上升至 36.42 GB，peak 達 51.05 GB；於回測執行階段，伴隨各組策略中介結果之累積，RSS 峰值達 47.38 GB，整體批次過程之 peak 維持於 51.05 GB。資料載入階段之記憶體佔用屬固定成本，與策略數量無關；策略展開後之記憶體增量則隨展開後策略數量變動。

表 4-6 啟用快取設定下五階段記憶體佔用

階段	RSS (GB)	peak working set (GB)
批次起始	0.06	—
資料載入後	10.92	12.81
V 構面展開後	36.42	51.05
條件解析／批次展開	36.42	51.05
策略預篩	28.98	51.05
回測執行	47.38	51.05
結果儲存	47.38	51.05

策略預篩階段 RSS 較前一階段下降，係因 Python 垃圾回收機制於該階段釋放部分中介物件；peak working set 則記錄自批次啟動以來之歷史峰值，故維持於 51.05 GB。扣除底層資料矩陣之固定成本 10.92 GB 後，本研究 2,084 組策略之變動記憶體佔用約 40.13 GB（以 peak 51.05 GB 為基準），平均每組策略約佔 19.7 MB。本研究使用之硬體環境配置 63.2 GB 實體記憶體，當前 peak 51.05 GB 已占實體記

記憶體 80.8%。據此線性外推，於相同硬體環境下，單機批次規模之承載上限約為 2,700 組策略，即當前規模再擴張約 30% 將逼近 64 GB 之承載上限。

上述推估僅針對單機環境下批次模式之承載上限，不適用於改採串流式（streaming）逐策略執行之模式。本研究選擇先展開後回測之設計，係為使每組策略之回測流程獨立、便於平行排程與結果審計。於批次規模超出單機承載上限時，可改採分批執行、結果輸出後釋放記憶體之策略，或升級硬體配置。於當前規模下，快取機制提供效能優化，於不影響回測結果之前提下節省約 2.4% 之執行時間；於批次擴張至承載上限附近之規模時，快取機制可減少重複 F[1] 中介結果之計算量，但其效益仍受限於可同時保有之中介結果數量，無法突破單機記憶體之上限。

4.4.3 工程驗收標準的滿足情況

依 3.1.3 節所定義之三項系統工程驗收標準，以下分別呈現各項於實作層面的驗證結果。

（一）可重現性：可重現性要求相同設定檔於相同引擎版本下執行應產出相同結果。

為驗證此項，本研究於不同時點以同一份 `fcv_experiment_spec.json` 重複執行至少 3 次完整批次回測，並對每次產出之策略結果檔案進行數值比對，所有執行結果完全一致。設定檔的版本控制與回測結果的標準化儲存共同確保了此一驗收標準。

（二）彈性擴充能力：在因子替換層次，本研究於系統設計階段（3.6.1 節所述之因子挑選過程）即實際驗證此一機制：30 餘項候選因子於同一宣告式引擎下分批執行，每替換一個因子，僅需修改 `fcv_experiment_spec.json` 中對應之 `field` 與 `conditions` 區段，引擎核心、批次展開邏輯與回測流程均未做任何程式碼修改。此一替換歷程橫跨獲利能力、現金流、應計、R&D、動量、波動等多個異質經濟構面，所涉及之條件類型亦涵蓋靜態截面門檻（`between`、`gte`、`lt_strict`）、橫斷面排名（`is_largest`）與動態跨期序列（`rise_q`、`yoy_gt`、`is_highest_q`）三類，足以證明系統之擴充能力非僅止於同類因子替換。

3.3.2 所述之條件類型擴充機制使新增一個靜態截面型僅需以單行 `lambda` 函

式定義；新增一個動態跨期型平均需新增 5 至 15 行程式碼於 `condition_factory.py` 中（行數視所需的時間窗口運算複雜度而定），且不影響 `batch_backtest.py` 與 `report_analysis.py` 任何邏輯。

- （三）回測偏誤的系統性修正：偏誤防控的工程實現以兩項機制為基礎。其一為時間軸對齊由底層引擎統一執行：3.5 節所述之四項法定公告對齊規則（年報對齊至次年 3 月 31 日、第一季報對齊至 5 月 15 日等）由資料存取層集中控管，所有策略組合於模擬交易節點上均僅取用該時點已公開之歷史資訊。其二為樣本範圍涵蓋歷史下市標的：本批次納入樣本期間內曾上市於台灣證交所之全部 1,775 間公司，含期間內已下市之標的，避免倖存者偏誤。兩項機制由系統架構承擔，而非散落於個別策略腳本中，符合 3.1.3 節所述「將偏誤防控的責任由個別腳本上移至系統架構」之設計目標。

綜合上述各項觀察，本研究系統在工程層面具備可行性：2,844 組策略的批次運算於 63.2 GB 記憶體環境下以約 66.5 分鐘完成，3.1.3 所定義之三項工程驗收標準均於實作層面取得對應驗證。本節結合 4.3 各節所呈現之策略有效性實證，共同構成本研究對 1.3 第三項研究目的（工程效能與財務績效兩個維度的量化驗證）之完整回應。

五、研究結論與限制

本研究以工程系統設計為切入點於既有回測平台基礎上設計並實作一套以宣告式設計為核心的通用量化回測引擎，並以台灣股票市場 2000 至 2024 年共 25 年的歷史資料為樣本，從工程效能與財務績效兩個維度檢驗系統與其所承載之 F-C-V 多層次選股框架。本章先依 1.3 節所列四項研究目的逐項收束本研究之主要工作與實證觀察，再界定本研究範圍上的限制與可延伸方向。

5.1 研究結論

5.1.1 宣告式回測引擎之設計與實作

本研究以結構化 JSON 設定檔作為策略宣告之外部介面，於底層引擎中以物件導向方式封裝靜態截面型與動態跨期型兩類異質計算邏輯，並透過條件解析工廠（`condition_factory.py`）將宣告轉譯為對應之布林遮罩函式。此一設計使研究者得以在不修改核心程式碼之前提下，透過更換設定檔切換因子組合與門檻區間，並由系統統一控管資料邊界與時間軸對齊邏輯。第三章所載之三層架構（資料存取層、邏輯運算層、應用層）以及本研究新建之三個模組（`condition_factory.py`、`batch_backtest.py`、`report_analysis.py`），共同構成此一引擎於工程上之具體實作。

5.1.2 F-C-V 多層次選股框架之建構

本研究於應用層之上建構整合體質、動態變化與估值三類因子之多層次選股框架，並將體質構面再分為基礎體質濾網（F[1]）與進階體質濾網（F[2]）以解耦排除壞標的與挑選好標的兩項分工。三構面之分層設計使體質、動態變化與估值各自之邊際貢獻得以於批次比較中獨立辨識。系統依固定展開規則自動生成 $F[1] \times F[2] \times C \times V$ 之策略集合，於 2000 至 2024 年樣本期間實際展開為 2,844 組策略，經換股次數門檻過濾後 2,084 組納入分析。各組策略均由同一套引擎邏輯統一驅動，於相同之資料邊界、時間軸與交易規則下執行，使大規模因子組合之系統性比較於工程上具備可行性。

5.1.3 工程效能與財務績效之雙維驗證

工程效能維度，本研究於 63.2 GB 記憶體之單機環境下完成 2,844 組策略之批次回測，總耗時約 66.5 分鐘，五階段分布顯示宣告解析與批次展開合計僅占 5.1%，工程上輕量，三項工程驗收標準（可重現性、彈性擴充能力、回測偏誤之系統性修正）均於實作層面取得對應驗證。

財務績效維度，本研究依 F-only、F+C、F+C+V 三組對照逐層檢驗 F-C-V 框架。整體策略空間於前 25% 之集合中，其績效並非由單一個股之極端報酬所驅動，平均 Top1 個股貢獻占比未超過 1.7%，獲利來源具備跨個股、跨年度之分散性。體質構面分析顯示單層 F[1] 已具方向性區辨能力，加入 F[2] 後同一 F[1] 區間內之績效分布得以進一步收斂，但兩個各自表現良好之因子疊加後並不必然產生加乘效果，因子間之交互作用須透過系統性批次比較方能辨識。動態變化構面之分析顯示，於不限體質條件下動態因子之相對效益難以辨識，於控制體質後 C1、C3、C6（皆衍生自獲利能力指標）取得較高之平均 CAGR，並於子樹固定下維持相對優勢。

估值構面之分析顯示 V1 並非單向之風險控制工具，僅約 21.1% 之策略同時取得風險下降之效果，其適用範圍受 F 與 C 之具體搭配條件限制；於 ROE 5–10 區間搭配 ROE 衍生之動態因子（C1、C2、C3）時，V1 於樣本期間內可同時降低風險並維持或提升 CAGR；惟此一搭配僅為架構運作下之觀察結果，不應外推為最終選股建議（此邊界於 5.2.6 進一步說明）。

5.1.4 介面改造之工程實作與適用前提

本研究於介面層面將既有之封閉式回測系統改造為以結構化 JSON 設定檔為輸入、以標準化儲存檔為輸出之形式，使系統之輸入輸出均不依賴互動式操作或內部記憶體狀態，符合可程式化呼叫之基本條件。此一介面形式對應 Yao 等人（2023）所指出之語言模型與外部工具互動所需之結構性前提，亦對應 Anthropic（2024, 2025）提出之 Model Context Protocol（MCP）對伺服器端之三項工程要求（呼叫進入點集中、輸入參數結構化、輸出格式可程式化解析）。具體而言，本系統之批次主程式作為單一執行入口、JSON 設定檔作為結構化輸入、標準化儲存檔作為結構化

輸出，三者分別對應 MCP 對伺服端之三項要求；後續若於本系統之上加入 MCP 協定介面層，將批次執行與結果讀取兩項操作分別暴露為 tool 與 resource，核心的回測引擎、條件解析工廠與批次展開邏輯均無須改動。本研究就此改造過程中之介面設計決策、條件解析工廠之抽象層建立方式與展開邏輯之固定取徑進行系統性記錄，可作為後續延伸應用於 AI 工具鏈整合之參考。

須一併指出者，本研究於 AI 工具鏈面向之貢獻僅止於介面前提之建立，實際整合之邊界於 5.2.5 進一步說明。

5.2 研究限制

5.2.1 樣本範圍與市場限制

本研究之樣本範圍限定於台灣證券交易所上市之普通股，未涵蓋上櫃市場與興櫃市場，亦未延伸至其他亞洲或全球市場。樣本期間雖橫跨 25 年，包含網路泡沫修正、全球金融海嘯、新冠疫情與通膨升息等多種市場狀態，但 F-C-V 框架於不同市場結構與制度環境下之穩健性仍待後續延伸驗證。

5.2.2 因子集規模與構面範圍

本研究以「具備代表性且能支撐 F-C-V 架構完整運作之最小因子集」作為驗證對象，於體質構面採四項因子、動態變化構面採八項衍生條件、估值構面僅以本益比為代表並固定為兩個對照配置（V0 與 V1）。此一因子集於支持架構有效性之主張上已屬充分；雖然系統於設計階段已實際測試過 30 餘項候選因子（3.6.1 節），相對於第二章 2.1 所述之 400 至 450 個全文獻候選因子規模，本研究最終呈現之實證範圍仍偏窄。本系統在工程上具備擴充至更大因子集之彈性，但此延伸驗證屬未來工作。

5.2.3 估值構面之條件空間未展開

V 構面於本研究中固定採 v0、v1 兩個對照配置，未對估值條件本身展開條件空間。此為本研究實證範圍上之決策而非系統能力上之限制，原因在於 V 之分析重點為「估值門檻納入前後之對照」，不需要與 F、C 同等規模之區間展開。後續

若有研究問題涉及多種估值條件之系統性比較（如本益比、股價淨值比、自由現金流殖利率之交叉比較，或不同估值區間之水準效應），可依循 F 與 C 之相同模式於 JSON 中宣告對應條件並納入批次展開，此一擴充於本系統之架構下不需修改核心程式碼。

5.2.4 策略空間規模化展開之多重檢定風險

本研究於 F-C-V 架構下展開為 2,844 組策略並納入分析者為 2,084 組，屬大規模批次比較。Harvey（2017）指出，於同一批資料上比較大量因子組合時，傳統 5% 的顯著水準門檻會嚴重低估偽陽性風險，所謂「最佳組合」於統計上有相當機率僅是雜訊而非真實效力。本研究於 4.3.1 透過 Top1 個股貢獻占比（前 25% 集合中平均上限約 1.7%）與 Effective N 分布（中位數約 350 至 370）兩項分散性指標，部分緩解此一風險之影響範圍。若高排名策略之績效高度依賴少數個股，則資料探勘成份較高；若獲利分散於數百檔個股，則架構之篩選能力較具實證基礎。然此一處理屬部分緩解而非完整解消，後續若需就特定因子組合之預測效力進行強統計推論，仍須另以樣本外測試或其他專屬方法處理。

5.2.5 AI 整合屬介面前提而非實作驗證

本研究於 AI 工具鏈面向之貢獻僅止於介面形式之適配性說明，並未實際完成 MCP server 之包裝、語言模型與本系統之串接，亦未對 AI 驅動之研究流程進行端到端之效果驗證。AI 可呼叫性於本研究中之操作化定義為「介面在形式上符合可程式化呼叫之三項工程前提」，而非「已完成 AI 整合」，此一邊界於 1.2、1.3、3.3.4 與 5.1.4 各節已多次明示，本節再次申明以避免誤解。

5.2.6 實證結果之適用範圍

第四章所呈現之實證結果記錄 F-C-V 架構於台灣股市 2000 至 2024 年樣本期間之表現，其驗證對象為宣告式系統作為實證工具之可行性，並非用以推導可推廣之選股法則或具體投資建議。各構面之邊際貢獻會因樣本期間、市場狀態與因子定義而異；第四章所示範之 ROE 5-10 子樹分析結果，係作為架構運作下之代表性觀察，不應外推為通用之投資建議。後續研究若以本研究系統為基礎延伸測試其他因子集

或市場樣本，應視為本架構之延伸應用，所得結果亦不應直接外推至本研究實證範圍以外之情境。

5.3 後續研究方向

基於本研究之系統與實證觀察，後續研究可循下列三條路徑延伸。

第一，因子集與構面之擴充。本系統之宣告式介面與條件類型擴充機制，使新增因子或新增條件類型於工程上具備低成本之可行性。後續研究可在 F、C、V 三構面內納入更多文獻所記載之候選因子（如品質因子之多種衡量、動量與反轉、低波動性等），亦可於既有四層之外延伸新的構面層級（如總體經濟條件層、產業輪動層）。架構上，新增構面僅需於批次展開邏輯中加入對應展開層，下層之條件解析工廠與回測引擎均不受影響。

第二，市場樣本與時間區間之延伸。本系統之資料存取層雖目前對接於 TEJ 台灣資料庫，但其封裝介面對外暴露之操作為標準化資料表查詢，理論上可替換為其他市場之資料來源。後續研究可將本系統延伸至上櫃市場、亞洲其他市場（如日本、韓國、香港）或美國等成熟市場，比較同一套 F-C-V 架構於不同市場結構與制度環境下之穩健性差異。

第三，AI 工具鏈之實作整合。本研究已就 MCP 對伺服器端之三項工程前提逐項對應確認，後續研究可於本系統之上加入 MCP 協定介面層，將批次執行與結果讀取兩項操作分別暴露為 tool 與 resource，並據此進行語言模型透過自然語言驅動回測之實作示範與效果驗證。此一延伸之核心工作集中於應用層之上之協定包裝，本研究之回測引擎、條件解析工廠與批次展開邏輯均無須改動，因此可作為下一階段研究之具體起點。

綜合而言，本研究於系統工程層面提供之主要貢獻，在於示範一套既有回測平台如何透過宣告式設計重構為具備可重現性、可審計性與外部可呼叫性之研究工具。此一改造思路於 AI 工具鏈快速發展之背景下具有可遷移性，本研究就此記錄之實作經驗與設計決策，可作為其他既有量化研究系統於介面外部化、條件抽象化與批

次展開機制三項議題上進行類似改造時之具體參照。於分析方法層面，提出以 F-C-V 三構面為基礎之分層比較框架：先以靜態截面型體質因子建立穩健資產池，再於控制體質構面之條件下比較動態跨期型因子之邊際貢獻，最後於控制體質與動態構面之條件下檢驗估值門檻之邊際貢獻，使各層次因子之貢獻得以在統一回測流程下獨立辨識，避免單一多因子模型中各因子貢獻相互混淆之問題。

六、參考文獻

- 李權恒 (2024)。雙因子選股邏輯對投資組合績效影響之研究〔未出版之碩士論文〕。國立中央大學資訊管理學系。
- 劉浩平 (2024)。整合分位數迴歸分析與單因子選股的股票選股策略回測與績效評估之研究〔未出版之碩士論文〕。國立中央大學資訊管理學系。
- Arnott, R., Harvey, C. R., & Markowitz, H. (2019). A backtesting protocol in the era of machine learning. *Journal of Financial Data Science*, 1(1), 64–74.
<https://doi.org/10.3905/jfds.2019.1.064>
- Asness, C. S., Moskowitz, T. J., & Pedersen, L. H. (2013). Value and momentum everywhere. *Journal of Finance*, 68(3), 929–985. <https://doi.org/10.1111/jofi.12021>
- Asness, C. S., Frazzini, A., & Pedersen, L. H. (2019). Quality minus junk. *Review of Accounting Studies*, 24(1), 34–112. <https://doi.org/10.1007/s11142-018-9470-2>
- Ball, R., Gerakos, J., Linnainmaa, J. T., & Nikolaev, V. (2016). Accruals, cash flows, and operating profitability in the cross section of stock returns. *Journal of Financial Economics*, 121(1), 28–45. <https://doi.org/10.1016/j.jfineco.2016.03.002>
- Bartram, S. M., Lohre, H., Pope, P. F., & Ranganathan, A. (2021). Navigating the factor zoo around the world: An institutional investor perspective. *Journal of Business Economics*, 91(5), 655–703. <https://doi.org/10.1007/s11573-021-01035-y>
- Basu, S. (1977). Investment performance of common stocks in relation to their price-earnings ratios: A test of the efficient market hypothesis. *Journal of Finance*, 32(3), 663–682.
<https://doi.org/10.1111/j.1540-6261.1977.tb01979.x>
- Campbell, J. Y., & Shiller, R. J. (1998). Valuation ratios and the long-run stock market outlook. *Journal of Portfolio Management*, 24(2), 11–26. <https://doi.org/10.3905/jpm.24.2.11>
- Chan, L. K. C., Jegadeesh, N., & Lakonishok, J. (1996). Momentum strategies. *Journal of Finance*, 51(5), 1681–1713. <https://doi.org/10.1111/j.1540-6261.1996.tb05222.x>
- Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22. <https://doi.org/10.1016/j.jfineco.2014.10.010>

- Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1994). *Design patterns: Elements of reusable object-oriented software*. Addison-Wesley.
- Graham, B. (2003). *The intelligent investor: The classic text on value investing* (Rev. ed., with commentary by J. Zweig). HarperBusiness.
- Harvey, C. R. (2017). Presidential address: The scientific outlook in financial economics. *Journal of Finance*, 72(4), 1399–1440. <https://doi.org/10.1111/jofi.12530>
- Harvey, C. R., & Liu, Y. (2019). *A census of the factor zoo* (SSRN Working Paper No. 3341728). SSRN. <https://doi.org/10.2139/ssrn.3341728>
- Jegadeesh, N., & Livnat, J. (2006). Post-earnings-announcement drift: The role of revenue surprises. *Financial Analysts Journal*, 62(2), 22–34. <https://doi.org/10.2469/faj.v62.n2.4081>
- Kowalski, R. (1979). Algorithm = logic + control. *Communications of the ACM*, 22(7), 424–436. <https://doi.org/10.1145/359131.359136>
- López de Prado, M. (2018). *Advances in financial machine learning*. Wiley.
- Pardo, R. (2008). *The evaluation and optimization of trading strategies* (2nd ed.). Wiley.
- Parnas, D. L. (1972). On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, 15(12), 1053–1058. <https://doi.org/10.1145/361598.361623>
- Piotroski, J. D. (2000). Value investing: The use of historical financial statement information to separate winners from losers. *Journal of Accounting Research*, 38(Suppl.), 1–41. <https://doi.org/10.2307/2672906>
- Sarasa-Cabezuelo, A. (2023). Development of a backtesting web application for the definition of investment strategies. *Knowledge*, 3(3), 414–431. <https://doi.org/10.3390/knowledge3030028>
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models [Paper presentation]. The Eleventh International Conference on Learning Representations (ICLR 2023), Kigali, Rwanda. https://openreview.net/forum?id=WE_vluYUL-X

Anthropic. (2024, November 25). *Introducing the Model Context Protocol*.

<https://www.anthropic.com/news/model-context-protocol>

Anthropic. (2025). *Model Context Protocol specification* (Version 2025-11-25).

<https://modelcontextprotocol.io/specification/2025-11-25>

附錄 1：實驗規格檔 fcv_experiment_spec.json

本研究批次實驗所採用之完整 fcv_experiment_spec.json 設定檔內容如下，此設定檔對應 3.3.1 節所述之三層嵌套結構：最外層為構面分區（P1 對應 F 構面、P3 對應 C 構面），第二層為因子，第三層為條件規格。每一個條件以固定語法 {type, args} 描述，type 標示條件類型、args 提供該類型所需之參數。

```
{  
  
  "P1": {  
  
    "ROE": {  
  
      "field": "report:roe",  
  
      "conditions": [  
  
        { "type": "lt_strict", "args": [5] },  
  
        { "type": "between", "args": [5, 10] },  
  
        { "type": "between", "args": [10, 15] },  
  
        { "type": "between", "args": [15, 20] },  
  
        { "type": "gte", "args": [20] }  
  
      ]  
  
    },  
  
    "EPS": {  
  
      "field": "report:eps",  
  
      "conditions": [  
  
        { "type": "lt_strict", "args": [0] },  
  
        { "type": "between", "args": [0, 2] },  
  
        { "type": "gte", "args": [2] }  
  
      ]  
  
    }  
  
  }  
}
```

```

},

"FCF_P": {

  "field": "report:fcf_p",

  "conditions": [

    { "type": "lt_strict", "args": [0] },

    { "type": "between", "args": [0, 0.05] },

    { "type": "gte", "args": [0.05] }

  ]

},

"DEBTRATIO": {

  "field": "report:debratio",

  "conditions": [

    { "type": "between", "args": [0, 0.35] },

    { "type": "between", "args": [0.35, 0.55] },

    { "type": "gte", "args": [0.55] }

  ]

}

},

"P3": {

  "ROE_SEQ": {

    "field": "report:roe",

    "conditions": [

      { "prefix": "C1_", "type": "is_highest_q", "args": [4] },

      { "prefix": "C2_", "type": "rise_q", "args": [1] },

```



```

    { "prefix": "C3_", "type": "yoy_gt", "args": [4] }

]

},

"REVENUE_GROWTH": {

    "field": "report:revenue",

    "conditions": [

        { "prefix": "C4_", "type": "is_highest_q", "args": [5] },

        { "prefix": "C5_", "type": "yoy_gt", "args": [4] }

    ]

},

"EPS_QOQ": {

    "field": "report:eps",

    "conditions": [

        { "prefix": "C6_", "type": "yoy_gt", "args": [4] },

        { "prefix": "C7_", "type": "ytd_avg_gt_prev_year_same_period_avg", "args": [] }

    ]

},

"FCF_MOM": {

    "field": "report:fcf_p",

    "conditions": [

        { "prefix": "C8_", "type": "rise_q", "args": [2] }

    ]

}

}}

```